

INTRODUCCION A LAS ECUACIONES ESTRUCTURALES EN AMOS Y R

Antonio Lara Hormigo

01/01/2014

INDICE

Introducción.....	4
Capitulo 1. Ecuaciones Estructurales.....	5
1.1 Tipos de variables en modelos de ecuaciones estructurales.....	5
1.2 Tipos de relaciones entre las variable.....	8
1.3 Tipos de de ecuaciones estructurales.....	10
1.4 Construcción de un modelo estructural.....	11
1.5 Etapa de estimación.....	13
1.6 Etapa de identificación.....	16
1.7 Diagnostico de la bondad de ajuste.....	16
Capitulo 2. Muestra y descripción del modelo de ecuaciones estructurales.....	23
2.1 Descripción de los datos.....	23
2.2 Fiabilidad de escalas. Alpha de Crombach.....	29
2.3 Modelo de ecuaciones estructurales.....	34
Capitulo 3. Aplicación utilizando el programa AMOS.....	34
3.1 Especificación del modelo.....	34
3.2 Estimación del modelo	38
Capitulo 4. Aplicación usando R.....	53
4.1 Especificación del modelo.....	53
4.2 Estimación del modelo	55
Bibliografía.....	

Introducción

Los orígenes de los modelos de ecuaciones estructurales (SEM) se encuentran en las técnicas desarrollado hace 90 años por Stewal Wright (Wright 1921), que lo desarrollo en el campo de la genética, cuyo propósito fue el de permitir "el examen de un conjunto de relaciones entre una o más variables independientes, sean estas continuas o discretas" desarrollando una forma de romper las correlaciones observadas en un sistema de ecuaciones matemáticas que describían sus hipótesis respecto a unas relaciones causales . Estas relaciones entre las variables fueron representadas en un "path diagram", conociéndose este método como "path analysis".

No existe ninguna definición que esté consensuada del concepto de modelo de ecuaciones estructurales, aunque hay numerosas definiciones que se han ido formulando a lo largo del tiempo de la que podemos destacar la de Byrne (1998) "un modelo de SEM es una metodología estadística que utiliza un enfoque confirmatorio del análisis multivalente aplicado a una teoría estructural relacionada con un fenómeno determinado".

Estos modelos son una serie de técnicas estadísticas, que se pueden considerar como una extensión de la otras técnicas multivalentes entre las que se pueden encontrar las regresión múltiple o análisis factorial que permiten a los investigadores cuantificar y comprobar teorías científicas pertenecientes a campos como la psicología, marketing, econometría o ciencias de la salud. Lo que se intentan conseguir con estos modelos de ecuaciones estructurales, es el estudio de las relaciones casuales entre los datos que sean directamente observables asumiendo que estas relaciones existentes son lineales.

Los modelos de ecuaciones estructurales constituyen una de las herramientas más potentes para los estudios de relaciones casuales sobre datos no experimentales cuando las relaciones son del tipo lineal. Esto hace que se haya convertido en una herramienta popular y generalmente aceptada para probar fundamentos teóricos en un gran número de disciplinas. La más relevante sean la economía y las ciencias sociales y del comportamiento que suelen enfrentarse a procesos cuya teoría es relativamente pobre, y suelen carecer de medios para controlar experimentalmente la recogida de información al fin de controlar las variables recogidas.

Capítulo 1 Ecuaciones estructurales

1.1 Tipos de variables en modelos de ecuaciones estructurales.


En estos modelos se distinguen los distintos tipos de variables según sea su medición o el papel que realizan dentro del modelo:

- Variable latente, reciben también el nombre de constructos, factores o variables no observadas según los diversos autores. Son normalmente el objeto de interés en el análisis, conceptos abstractos que pueden ser observados indirectamente a través de sus efectos en los indicadores o variables observadas.
- Variable observada, o también denominada de medidas o indicadoras, son aquellas variables que pueden ser medidas.

Entre las variables latentes, podemos destacar tres tipos de variables, que son:

- Variable exógena, son variables latentes independientes, es decir, afectan a otras variables y no recibe ningún efecto de ninguna de ellas. Estas variables se pueden detectar en las gráficas porque no salen ninguna de las flechas de esta variable. En la figura 1 se puede observar como V_3 es una variable endógena, puesto que no recibe información de V_1 ni de V_2 , pero si aporta información a estas variables, por tanto V_3 es una variable exógena.
- Variable endógena, variables latentes dependientes, son aquellas que reciben el efecto de otras variables, es decir, en las gráficas son las variables a las que llegan las flechas. Estas variables están afectadas por un término de perturbación o de error. En la figura 1, tenemos que tanto V_1 como V_2 reciben información la una de la otra. De esta forma, V_1 y V_2 son de esta forma variables endógenas.
- Variable error, este término tiene en cuenta todas las fuentes de variación que no están consideradas en el modelo. Como puede ser en la medición de las variables. Se denominan variables de tipo latente al no ser observables.

Figura 1. Variables exógenas y endógenas.



Representación visual.

Los sistemas de ecuaciones estructurales se suelen representar de forma visual en diagramas causales o en “path diagrams”. Esta técnica se sirve de grafos que reflejan el proceso haciendo estos diagramas acordes con las ecuaciones.

1) Las relaciones entre las variables se indican por una flecha cuyo sentido es desde la variable causa hacia la variable efecto. Cada una de estas relaciones está afectada por un coeficiente, que indica la magnitud del efecto entre ambas variables, si entre dos variables no se ha especificado ninguna relación (flecha) se entiende que su efecto es nulo.

2) La relación entre dos variables exógenas o de dos términos de perturbación sin una interpretación causal, se representa con una flecha bidireccional que une a ambas variables, y el parámetro asociado se indica con una varianza.

3) En los sistemas de ecuaciones estructurales se suele incluir dos tipos de variables, observables y latentes. Las variables observables suelen ir enmarcados en los diagramas mediante cuadrados y las variables latentes están representadas con círculos u óvalos.

4) Los parámetros del modelo se representan sobre la flecha correspondiente.

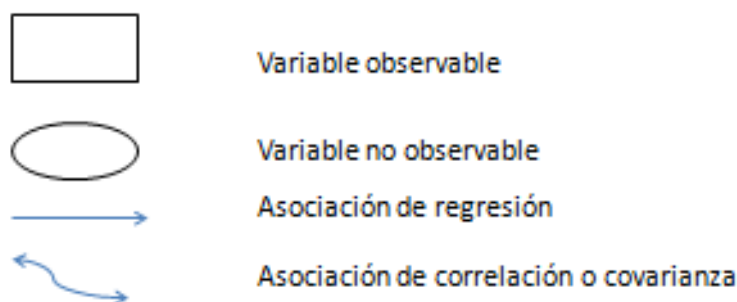
Con estas reglas se suelen representar todas las teorías causales y de medición de forma equivalente a la que lo hacen los sistemas de ecuaciones, mientras que cumplan:

- 1) Todas las relaciones casuales deben estar representadas en el diagrama
- 2) Todas las variables que son causas de las variables endógenas deben de estar incluidas en el diagrama
- 3) El diagrama deben ser sencillo, y solo contengan relaciones que puedan justificarse con bases teóricas.

Por este motivo, los diagramas de ecuaciones estructurales siguen unas convenciones particulares para derivar las ecuaciones correspondientes:

- Las variables observables se representan encerradas en rectángulos
- Las variables no observables se representan encerradas en óvalos o círculos.
- Los errores se representan sin círculos ni rectángulos.
- Las relaciones bidireccionales se representan como líneas curvas terminadas en flechas en cada extremo.
- Las relaciones unidireccionales se representan con una flecha.

Figura 2. Elementos de la representación visual.



En función de las características de los modelos se pueden diferenciar entre los modelos en los que los errores no están relacionados y todos los efectos causales son unidireccionales, que son los llamados modelos recursivos, y aquellos en los que existen lazos de retroalimentación o pueden tener errores correlacionados, estos se llaman modelos no recursivos. Además, no es necesario aclarar si los modelos son recursivos, o no recursivos ya que esto se puede diferenciar claramente en el diagrama estructural.

1.2 Tipos de relaciones entre las variables.

Para desarrollar este punto, se empezará a definir qué tipos de relaciones casuales pueden establecerse entre dos variables v_1 y v_2 :

- v_1 y v_2 pueden estar relacionadas si v_1 causa v_2 , lo que implicaría asumir un modelo de regresión de v_2 a v_1 , también pueden estar relacionadas si v_2 causa a v_1 , lo que asumiría el modelo de regresión de v_1 sobre v_2 , como se puede observar en figura 3. En ambos casos se esta hablando de relaciones directas, aunque estas también pueden ser reciprocas, como se contemplan la siguiente figura 4, en este caso la casualidad será bidireccional:

Figura 3. Relaciones entre variables.





Figura 4. Relaciones entre variables.




- v_1 y v_2 asimismo estarán relacionadas si ambas se tienen una causa común a una tercera variable interviniente v_3 . A esta relación se le denomina relación *espurea*, y se puede observar en la figura 5.

Figura 5. Relaciones entre variables.




- v_1 y v_2 asimismo estarán relacionadas si ambas están relacionadas a una tercera variable interviniente v_3 . A esta relación se le llama relación indirecta y se representa en la figura 6.

Figura 6. Relaciones entre variables.



- Existe un último tipo de relación, y que puede emparentarse tanto con la relación espúrea y con la relación indirecta. Esta última relación se muestra en la figura 7 en donde, la diferencia entre las relaciones anteriores, es que en esta última, v_1 y v_3 son ambas relaciones exógenas y carecen de mecanismo causal explícito que las relaciones entre sí, dejando la relación entre ambas variables como no explicada. Esto deriva en una dificultad de determinar si la relación entre v_1 y v_2 es por vía espúrea o indirecta. Por ese motivo, se ha definido este nuevo efecto como efecto conjunto.


Figura 7. Relaciones entre variables.



1.3 Tipos de ecuaciones estructurales

Los modelos de ecuaciones estructurales, pueden ser de dos tipos, modelo de medida y modelo de relaciones estructurales. En el modelo de medida ver figura 8 se representan las relaciones de las variables latentes con sus variables observadas o indicadoras, y donde las variables latentes están relacionadas mediante una covariación. Este modelo permite corroborar la idoneidad de los indicadores en la medición de las variables latentes. Podemos distinguir este tipo de ecuaciones, porque las variables latentes están relacionadas entre sí por flechas bidireccionales, como en la figura 8.


Figura 8. Modelo de medida.



En el modelo de relaciones estructurales (ver figura 9) contiene los efectos y relaciones entre las variables latentes, es parecido a un modelo de regresión pero puede contener efectos concatenados y bucles entre variables. Además, contienen los errores

de predicción. Como se observan en la figura 9, se pueden distinguir el modelo de relaciones estructurales al tener las variables latentes relaciones de regresión entre sí, como sucede con la variable V_3 .

Figura 9. Modelo de estructura.



1.4 Construcción del modelo estructural

Etapa de especificación

La especificación es el ejercicio de establecer formalmente un modelo, que en esencia es una explicación teórica plausible de por qué las variables están o no relacionadas. En los modelos las especificaciones implican formular las sentencias sobre un conjunto de parámetros, que según sean éstos, se distinguirán los parámetros en tres tipos: libres (desconocidos y no restringidos), no restringidos dos o más parámetros que deben de tomar el mismo valor aunque estén restringidos) o fijos (conocidos a los que se les da un valor fijo).

El número máximo de relaciones y estadísticos asociados a las mismas que son capaces de estructurar los datos según una cierta teoría, es lo que entenderemos por modelo estadístico. La inclusión del término máximo obedece a que cuanto mayor sea el número de supuestos introducidos, mas restrictivo será el modelo y por lo tanto menos parco y sencillo.

El grado de conocimiento teórico que posea el investigador sobre el tema de estudio matizara la estrategia a seguir en la construcción del modelo. De esta forma cuantos más conocimientos se tenga, se puede ver traducido a la especificación del modelo concreto. En cuyo caso, el investigador tendrá como objetivo el rechazar o aceptar le modelo, denominándose esta estrategia a menudo con el nombre de análisis confirmatorio.

Por este motivo el modelo estructural es aquel componente del modelo general que describe las relaciones causales entre las variables latentes. En definitiva habrá tantas ecuaciones estructurales como constructos latentes que sean explicadas por otras variables exógenas, ya bien sean latentes u observadas. La estructura se puede expresar de la siguiente manera:

$$\eta = \beta\eta + \Gamma\xi + \zeta \quad (1)$$

Donde:

η es un vector “p x 1” de variables endógenas latentes.

ξ es un vector “q x 1” de variables exógenas latentes.

Γ es una matriz ”p x q” de coeficientes γ_{ij} que relacionan las variables latentes exógenas con las endógenas.

β es una matriz “q x p” de coeficientes que relacionan las variables latentes endógenas entre sí.

ζ es un vector “q x 1” de errores o términos de perturbación. Indican que las variables endógenas no se predicen perfectamente por las ecuaciones estructurales.

Por otra parte, las variables latentes están relacionadas con variables observables a través del modelo de medida, que está definido tanto por variables endógenas como por variables exógenas de través de las siguientes expresiones:

$$y = \Lambda_y \eta + \varepsilon \quad y \quad x = \Lambda_x \xi + \delta \quad (2)$$

Donde

η es un vector “m x 1” de variables latentes endógenas.

ξ es un vector “k x 1” de variables latentes exógenas.

Λ_x es una matriz “q x k” de coeficientes de variables exógenas.

Λ_y es una matriz “p x m” de coeficientes de variables endógenas.

δ es un vector “q x 1” de errores de medición para los indicadores exógenos.

ε es un vector “p x 1” de errores de medición para los indicadores endógenos.

x es el conjunto de variables observables del modelo de medida.

y es el conjunto de variables observables del modelo de estructura.

1.5 Etapa de estimación

En esta fase se pueden emplear diferentes tipos de estimación de los parámetros, con el objetivo de determinar cuál de ellos presentan un mejor ajuste: máxima verosimilitud, mínimos cuadrados ponderados y mínimos cuadrados generalizados.

Estimación por máxima verosimilitud (ML)

Este método es el más utilizado en el ajuste de modelos de ecuaciones estructurales, al proporcionar estimaciones consistentes, eficientes y no segasdas con tamaños de muestras no suficientemente grandes. La estimación por ML exige que las variables estén normalmente distribuidas, aunque la violación de la condición de normalidad multivariante no afecta a la capacidad del método para estimar de forma no sesgada los parámetros del modelo. Aunque es capaz de facilitar la convergencia de las estimaciones aún con la ausencia de normalidad. Para muestras pequeñas que no cumplan la normalidad de los datos, se puede utilizar este método de estimación con la aplicación de procedimientos de bootstrap, que permite obtener estimaciones de los errores estándar de los parámetros del modelo.

La función de log-verosimilitud es:

$$\log L = -\frac{1}{2}(N-1)\{\log|\Sigma(\theta)| + \text{tr}[S\Sigma(\theta)^{-1}]\} + c \quad (3)$$

Para maximizar la función anterior, es equivalente a minimizar la siguiente función:

$$F_{ML} = \log|\Sigma(\theta)| - \log|S| + \text{tr}[S\Sigma(\theta)^{-1}] - p \quad (4)$$

Siendo:

L la función de verosimilitud, N el tamaño de la muestra, S la matriz de covarianza de la muestra, $\Sigma(\theta)$ es la matriz de covarianzas del modelo y θ es el vector de los parámetros.

Estimación por mínimos cuadrados ponderados (WLS)

Este método tiene entre algunas de sus ventajas la posibilidad de introducir en los análisis variables ordinales, variables dicotómicas y variables continuas que no se ajusten a criterios de normalidad, siendo de esta forma unos de los métodos más utilizados y recomendados ante la falta de normalidad de los datos. Este método minimiza la función de ajuste:

$$F_{WLS} = [s - \sigma(\theta)]' W^{-1} [s - \sigma(\theta)] \quad (5)$$

Donde, s es el vector de elementos no redundantes en la matriz de covarianzas empíricas, $\sigma(\theta)$ es el vector de elementos no redundantes en la matriz de covarianzas del modelo, θ es un vector de parámetros ($t \times 1$), W^{-1} es una matriz ($k \times k$) definida positiva con $k = \frac{p(p+1)}{2}$ donde p es el numero de variables observadas, donde $W^{-1} = H$ la función de los momentos de cuarto orden de las variables observables.

Este método de estimación, tiene entre sus desventajas, que el valor del estadístico ji-cuadrado (que se definirá posteriormente) será preciso siempre que la muestra sea suficientemente grande. Además, no se podrá aplicar este método si hay un gran número de variables indicadoras, ya que la matriz de pesos asociadas aumentara considerablemente su valor. Es decir, si p es el numero de variables observadas, la matriz de pesos será del orden de (k, k) siendo $k = \frac{p(p+1)}{2}$ de forma que si tenemos un modelo con 8 variables, la matriz W^{-1} sería del orden (36×36) con lo que se debería tener 1296 elementos no redundantes.

Estimación por mínimos cuadrados generalizados (GLS)

Este método es un caso especial dentro de la estimación por mínimos cuadrados ponderados, aunque en este método se exige que los datos estén bajo condiciones de normalidad multivariante. Este método es asintóticamente equivalente al F_{ML} , puesto que se basan en los mismos criterios y se pueden emplear bajo las mismas condiciones, aunque es más apropiado utilizar este método si no tenemos una muestra pequeña de los datos. Además resulta inapropiado cuando el modelo aumenta de tamaño y complejidad

La función de ajuste se puede escribir de la forma:

$$F_{GLS} = \frac{1}{2} tr\{[S - \Sigma(\theta)]S^{-1}\}^2 \quad (6)$$

Donde, S es la matriz de covarianzas empíricas, $\Sigma(\theta)$ es la matriz de covarianzas del modelo, θ es un vector de parámetros ($t \times 1$).

1.5 Etapa de identificación

La aplicación de los modelos estructurales tiene por finalidad estimar los parámetros desconocidos del modelo especificado, para después contrastarlo estadísticamente. Un modelo estará identificado si los parámetros del modelo pueden estimarse a partir de los elementos de la matriz de covarianzas de las variables observables.

De esta forma se tiene que el llamado problema de identificabilidad del modelo, consiste en estudiar bajo qué condiciones se pueden garantizar la unicidad en la determinación de los parámetros del modelo.

Por este motivo, se va a definir el concepto de grado de libertad como la diferencia entre el número de varianzas y covarianzas, y el de parámetros a estimar, con lo que g no puede ser negativo para poder realizar el estudio. Si denotamos el número total de variables con $s = p + q$, siendo p las variables endógenas y q las variables exógenas, se tendrá que el número de elementos no redundantes es igual a $\frac{s(s+1)}{2}$, y al número total de parámetro que han de ser estimados en el modelo como t , se define

$$g = \frac{s(s+1)}{2} - t$$

Según el valor de g podemos clasificar los modelos en:

- Nunca identificado ($g < 0$) modelos en los que los parámetros toman infinitos valores. Y por ellos están indeterminados.
- Posiblemente identificado ($g = 0$) modelos en los que puede existir una única solución para los parámetros que iguale la matriz de covarianzas observada e implicada.
- Posiblemente sobreidentificados ($g > 0$) modelos que incluyen menos parámetros que varianzas y covarianzas. En estos modelos no existe ninguna solución para los parámetros que iguale la matriz de covarianzas observada, pero puede existir una única solución que minimice los errores entre ambas matrices.

1.7 Diagnostico de la Bondad de ajuste

Esta puede que sea la etapa más importante de la modelización de una ecuación estructural. En esta etapa se intenta determinar si el modelo es correcto y si es útil para

nuestros propósitos. Debemos entender por modelo correcto aquél que incorpora aquellas restricciones y supuestos implícitos que se cumplen en la población y especifica correctamente las relaciones entre las variables sin omisión de parámetros, prediciendo adecuadamente la realidad, es decir, conduce a diferencias reducidas y aleatorias entre las varianzas y covarianzas observadas y las implícitas del modelo

Se tiene que destacar que hay asociados un gran número de índices adecuados de bondad de ajuste que serán necesarios interpretar para concluir si el modelo es adecuado. Su correcta interpretación, tanto global como individual, hará que aceptemos o rechacemos el modelo planteado.

El estadístico χ^2 de bondad de ajuste

Es la única medida de bondad de ajuste asociada a un test de significación asociado, el resto de medidas e índices son descriptivos. Este estadístico viene proporcionado por el mínimo de la función de ajuste F, el cual sigue una distribución χ^2 , con los mismos grados de libertad que el modelo, y que permite contrastar la hipótesis de que el modelo se ajusta bien a los datos observados. El nivel asociado a este estadístico indica si la discrepancia entre la matriz reproducida y la correspondiente a los datos originales es significativa o no. Para aceptar el modelo se debe de tener que la probabilidad p de obtener un valor χ^2 tan alto como el modelo es inferior a 0.05, el modelo es rechazado.

El gran problema que tiene este estadístico, es que se ve muy influenciado por tres factores que le hacen perder la eficacia:

- El estadístico χ^2 se ve muy influenciado por el tamaño de la muestra, de forma que, para tamaños de muestras superiores a 200 el valor de χ^2 tiende a ser significativo, rechazando modelos que en la realidad se apartan muy poco de los datos observados. Y contrariamente, si los tamaños de muestras son relativamente pequeños, el test no es capaz de detectar discrepancias significativas aceptando modelos que no se ajustan bien a los datos.
- Si la complejidad del modelo es alta, tiene una mayor probabilidad de que el test acepte el modelo, teniéndose que en los modelos saturados, proporcionara un ajuste perfecto. Esto se debe a que el estadístico χ^2 evalúa la diferencia entre el modelo del

investigador y una versión saturada de este modelo, por lo que cuando más próximo esté el modelo del investigador a esta versión mayor será la probabilidad de obtener un buen ajuste.

- El estadístico χ^2 es muy sensible a la violación de la suposición de normalidad multivariante para las variables observadas. Hay que recordar que de los tres métodos que se explicaron anteriormente, el método de ML no requería la normalidad multivariante de los datos (pero si la normalidad univariante) y el método WLS ni siquiera exigía la normalidad univariante de los datos. Solo para el método GLS tenemos exigida la normalidad multivariante para el procedimiento del modelo.

De esta forma se tendrá que el estadístico es:

$$\chi^2(df) = (N - 1)F[S, \Sigma(\hat{\theta})] \quad (7)$$

Donde, $df = s - t$ grados de libertad, s es el número de elementos no redundantes en S t es el número total de parámetros a estimar, N es el tamaño de la muestra, S es la matriz empírica, $\Sigma(\hat{\theta})$ es la matriz de covarianzas estimadas.

De esta forma se tiene que el estadístico χ^2 depende del método de estimación elegido. De esta forma tenemos que el estadístico se calcula, dependiendo del método elegido de la siguiente forma:

$$\chi^2_{ML}(df) = (N - 1)[Tr(S \Sigma(\hat{\theta})^{-1}) - (p + q) \ln|\Sigma(\hat{\theta})| - \ln|S|] \quad (8)$$

$$\chi^2_{GLS}(df) = (N - 1)[0,5Tr((S - \Sigma(\hat{\theta}))S^{-1})^2] \quad (9)$$

$$\chi^2_{WLS}(df) = (N - 1)[0,5Tr(S - \Sigma(\hat{\theta}))^2] \quad (10)$$

Medidas incrementales

Nos referimos a ellas como las medidas incrementales de ajustes o medidas descriptivas basadas en la comparación de los estadísticos χ^2 con otro modelo más restrictivo llamado modelo base. Convencionalmente se toma como modelo base aquel que no restringe en modelo alguno las varianzas de la variables, pero asume que todas sus covarianzas son cero, al que se le denomina modelo de independencia. Con la realización de los modelos, se busca aproximaciones simplificadas de los datos. Por ese motivo se ha desarrollado una serie de índices que comparan la mejoría en la bondad de ajustes de un modelo base (que usualmente es el modelo nulo con lo que las variables no estarían relacionadas). Las medidas empleadas son el índice de ajuste normado (NFI), el índice no normado (NNFI) y el índice de ajuste comparativo (CFI). Estos índices de bondad de ajustes, al comparar el estadístico χ^2 suelen estar acotados entre 0 y 1, donde el 1 representa un ajuste perfecto.

- El más sencillo de todos es el NFI, índice ajuste normado (Normed Fit Index de Bentler y Bonnett 1980), este estadístico evalúa la disminución del estadístico χ^2 de nuestro modelo con respecto al modelo nulo. Este índice no es aconsejable porque no tiene en cuenta los grados de libertad, favoreciendo de esta forma la adopción de los modelos sobreparametrizados, ya que aumenta su valor siempre que se añade más parámetros a un modelo. Este índice toma valores entre 0 y 1, siendo mejor el ajuste cuando más próximo este a 1. Por convención, valores inferiores a 0,90 indicaran la necesidad de reespecificar el modelo, aunque algunos autores admiten un punto de corte más relajado. Se representara (donde χ^2_b es el estadístico del modelo base):

$$NFI = \frac{\chi^2_b - \chi^2}{\chi^2_b} \quad (10)$$

- El índice de ajuste no normado (NNFI) o también llamado el índice de Tucker-Lewis (TLI) está corregido para tener en cuenta la complejidad del modelo. Por este motivo no introducen directamente el estadístico χ^2 , sino que los compara previamente con su esperanza, los grados de libertad del modelo nulo con los del modelo en cuestión. Por tanto, si se añaden parámetros al modelo, el índice solo aumentara si el estadístico χ^2 disminuye en mayor medida que los grados de libertad. Los valores del

índice NNFI suelen variar entre 0 y 1, aunque pueden no estar restringidos a este rango, es decir, la cota superior no es la unidad y valores superiores a 1 tienden a indicar sobreparametrización del modelo. Los valores próximos a 1 indican un buen ajuste.

$$NNFI = \frac{\chi^2_b / g_{lb} - \chi^2 / g}{\chi^2_b / g_{lb} - 1} \quad (11)$$

- El CFI, índice de ajuste comparativo (Comparative Fit Index, de Bentler 1990) compara la discrepancia entre la matriz de covarianzas que predice el modelo y la matriz de covarianzas observada, con la discrepancia entre la matriz de covarianzas del modelo nulo y la matriz de covarianzas observadas para evaluar el grado de pérdida que se produce en el ajuste al cambiar del modelo del investigador al modelo nulo. Este modelo está corregido con respecto a la complejidad del modelo. Los valores del índice varían entre 0 y 1. Por convención, el valor de CFI debe ser superior a 0,90 indicando que a menos el 90% de la covarianza en los datos puede ser reproducida por el modelo.

$$CFI = 1 - \frac{\text{Max}[(\chi^2 - gl), 0]}{\text{Max}[(\chi^2 - gl), (\chi^2_b - gl_b), 0]} \quad (12)$$

Medidas de selección del modelo

Existen otros índices descriptivos de la bondad de ajuste global que no pertenecen a la familia de los índices de ajustes incrementales y que no están acotados. Al no estar acotados, estos son difíciles de interpretar para un modelo aislado, pero son especialmente útiles cuando se trata de comparar modelos que se basen en las mismas variables y datos, pero con distintos números de parámetros, ya que tienen en cuenta la sencillez del modelo. Estos índices son el AIC y el CAIC. La utilidad de estos índices reside en comparar modelos que poseen diferentes números de variables latentes, siendo mejor modelo aquí que tenga el valor de estos índices más pequeño.

- AIC (Akaike Information Criterion, Akaike 1987) este índice ajusta el estadístico χ^2 del modelo penalizando la sobreparametrización.

$$AIC = \chi^2 - 2gl \quad (13)$$

- CAIC (Consistent AIC, Bozdgan 1987) que se basa en una transformación consistente del índice anterior.

$$CAIC = \chi^2 - gl(\ln(N) + 1) \quad (14)$$

Índices basados en la covarianzas del modelo.

Un modelo en el que se impongan muchas restricciones siempre se ajustan a los datos, incluso aunque el modelo no tenga sentido alguno desde la perspectiva del fundamento teórico que debería sustentarlo. Al añadir parámetros al modelo, esto hace que el ajuste aumente, pero también aumenta su complejidad. El índice siguiente penaliza el ajuste por la pérdida parsimonia al aumentar la complejidad.

- RMSEA (Root Mean Square Error of Aproximation, BRowne y Cudeck, 1993). Este índice está tomando mucha popularidad, se puede interpretar como el error de aproximación medio por grado de libertad. Valores por debajo del 0,05 indican un buen ajuste del modelo, y por debajo del 0,08 indican un ajuste adecuado del modelo. La distribución en el muestreo del RMSEA se ha deducido (Hu y Bentler, 1999) permitiendo construir intervalos de confianza. Donde se consideran que los extremos de los intervalos de confianzas debe de ser inferiores a 0,05 (o 0,08) para que el ajuste sea aceptable. Este estadístico se puede calcular de forma que :

$$RMSEA = \sqrt{\frac{NCP}{N \times gl}} \quad (15)$$

Donde NCP es el llamado parámetro de no centralidad que se puede calcular como $NCP = \text{Max}[\chi^2 - 2gl, 0]$.

Al depender este índice de las unidades de medida, se suele tomar otro estadístico que será el resultado de estandarizar al anterior, SRMR (Standarized Root Mean Square Residual) obtenido al dividir el valor de RMSEA por la desviación típica. Este valor se consideran indicativos de un buen ajuste si está por debajo del valor 0,05.

Hay autores como Hu Bentler (1999) que muestran como los índices de SRMR, RMSEA, NNFI y CFI son propensos a rechazar modelos correctos cuando el tamaño de

la muestra es pequeño. Deberemos tener cuidado y ser suficientemente flexible para no emplear un índice concreto sino emplear una combinación de varios de estos índices.

Capítulo 2. Muestra, descripción del modelo de ecuaciones estructurales.

2.1 Descripción de los datos.

La muestra está compuesta por un total de 349 trabajadores de las distintas universidades de Andalucía. Del total de la muestra se cuenta con 177 hombres (50,7%) y 172 mujeres (49,3%). Las edades de los trabajadores, se tiene que 2 trabajadores tenían menos de 25 años (0,6%), 16 personas tenían entre 26 y 35 años (4,6%), 201 trabajadores tenían entre 36 y 45 años (57,6%), 112 tenían entre 46 y 55 años (32,1%), y 18 trabajadores eran mayores de 55 años (5,2%). La distribución de los trabajadores por el nivel de estudio fue de 2 trabajadores sin estudio (0,6%), 1 en escolaridad (0,3%), 38 con educación primaria (10,9%), 90 con educación secundaria (25,8%), 108 licenciados (30,9%) y 104 doctorados (29,8%) donde se ha tenido 6 datos perdidos (1,7%). La distribución del régimen jurídico se tiene que 337 son funcionarios (96,6%) y 12 son Laboral (3,4%). El nivel de los puestos de trabajo tiene una distribución de 300 predirectivos y operarios (86%) y 49 directivos de (14%).

Se ha utilizado dos escalas, la primera escala, estrés de rol, está compuesta de tres subescalas, ambigüedad, conflicto y sobrecarga con 17 ítems, cuyas respuestas oscilan entre 1 (muy en desacuerdo) y 5 (muy de acuerdo). La segunda escala, es el Bornout, que tiene tres subescalas, despersonalización, agotamiento y falta de realización personal con 9 ítems, cuyas respuestas oscilan entre 1 (muy en desacuerdo) y 5 (muy de acuerdo),

En primer lugar se describirá el contenido inicial de la matriz de los datos originales, procediendo al análisis descriptivo de los datos de la encuesta, y a continuación se pondrá a prueba el modelo global teórico propuesto.

En la tabla 1 contiene los principales estadísticos descriptivos de las variables de observadas, que serán las que formen parte del modelo de ecuaciones estructurales con el que se inicia el estudio, donde las variables X_i son las variables obtenidas del cuestionario del estrés de rol, y las variables Y_j son las variables obtenidas del cuestionario de Bornout. Las variables del estrés de rol están divididas en 3 grupos,

Ambigüedad (formada por los ítems del X1 al X6), Conflicto (formado por los ítems del X7 al X14) y Sobrecarga (formado por los ítems del X15 al X16) y las variables del Bornout están formada por tres grupos que son el Despersonalización (formado por los ítems Y1 al Y3) del agotamiento Emocional (formado por los ítems del Y4 al Y9) y la Falta de realización personal formada por los ítems (del Y6 al Y9).

Tabla 1. Estadísticos descriptivos de las variables observadas.

	Media	Desv. típ.	Asimetría	Error típ. de asimetría	Curtosis	Error típ. de curtosis
X1	4,201	0,841	-1,210	0,131	1,701	0,260
X2	3,989	0,938	-0,861	0,131	0,266	0,260
X3	4,209	0,758	-1,047	0,131	1,817	0,260
X4	4,252	0,897	-1,360	0,131	1,731	0,260
X5	4,172	0,943	-1,217	0,131	1,152	0,260
X6	3,911	1,031	-0,801	0,131	-0,156	0,260
X7	3,401	1,088	-0,553	0,131	-0,420	0,260
X8	2,857	1,219	0,027	0,131	-1,003	0,260
X9	2,438	1,257	0,332	0,131	-1,085	0,260
X10	2,857	1,287	-0,047	0,131	-1,136	0,260
X11	2,473	1,231	0,268	0,131	-1,055	0,260
X12	2,805	1,318	0,046	0,131	-1,187	0,260
X13	2,570	1,259	0,323	0,131	-1,066	0,260
X14	2,481	1,235	0,402	0,131	-0,920	0,260
X15	2,797	1,225	0,055	0,131	-1,031	0,260
X16	2,817	1,218	0,115	0,131	-0,911	0,260
X17	2,805	1,276	0,136	0,131	-1,070	0,260
Y1	1,885	1,171	1,120	0,131	0,102	0,260
Y2	1,693	1,012	1,414	0,131	1,166	0,260
Y3	1,470	0,849	2,020	0,131	4,002	0,260
Y4	3,009	1,183	-0,184	0,131	-0,861	0,260
Y5	2,722	1,282	0,120	0,131	-1,134	0,260
Y6	2,103	1,120	0,759	0,131	-0,355	0,260
Y7	4,129	0,936	-1,379	0,131	2,229	0,260

Y8	3,785	0,978	-0,800	0,131	0,647	0,260
Y9	4,307	0,810	-1,562	0,131	3,590	0,260

A la vista de estos valores estadísticos, se entiende que existe normalidad univariada de los datos. Una de las formas típicas de validar la normalidad de un conjunto de datos reside en el estudio y análisis de la curtosis y asimetría que representan las variables. Según Curran, West y Finch (1996) establecen los límites, en valor absoluto, hasta los que se pueden considerar un comportamiento semejante al normal, en los valores comprendidos entre 2 para la asimetría y 7 para la curtosis, moderadamente normal para los valores comprendidos entre 2 y 3 para la asimetría y entre 7 y 21 para la curtosis y extremadamente no normal para valores superiores a 7 en la asimetría y de 21 de curtosis. Por tanto en la tabla 1 podemos comprobar que los datos cumplen con estas condiciones, es decir, podemos ver que todas las variables tienen un valor de asimetría menor que 2 (salvo Y3 que tiene un valor de 2,020 que es inferior a 3) y los valores de curtosis son menores que 7. Siendo los datos, como se indicó anteriormente, distribuidos con una normalidad univariada. También se ha realizado el test de Mardia (en el programa R con el paquete MVN) obteniendo como resultado que los datos no siguen una distribución normal multivariante.

```

mardiaTest(Datos)
Mardia's Multivariate Normality Test
g1p      : 114.5408
chi.skew  : 6662.458
p.value.skew : 3.970506e-233
g2p      : 855.1927
z.kurtosis : 31.1361
p.value.kurt : 0
chi.small.skew : 6723.997
p.value.small : 5.868454e-240
Result    : Data is not multivariate normal.

```

También vamos a estudiar las relaciones de correlación de los datos que se puedan establecer entre las variables observadas. Para este análisis se incluye en la tabla 2 la matriz de correlaciones de las variables observadas, en esta tabla podemos comprobar que existen una estructura de de correlación entre las variables observadas. Más concretamente, podemos observar como las correlaciones más altas se encuentran en cada grupo de variables, produciendo correlaciones más altas entre los ítems referentes

a la Ambigüedad (X1,...,X6), Conflicto (X7,...,X14), Sobrecarga (X15,...,X17), Despersonalización (Y1,Y2 y Y3) Agotamiento emocional (Y4, Y5 y Y6) y Falta de realización personal (Y7, Y8 y Y9).

Esto demuestra la existencia de una estructura de correlación compleja entre las variables observadas, lo cual a su vez hace que sea pertinente pensar en el diseño de un modelo de ecuaciones estructurales. De esta forma se tiene claramente que los constructos o variables latentes existentes en este conjunto de datos son 6, que son los correspondientes a cada una de los grupos.

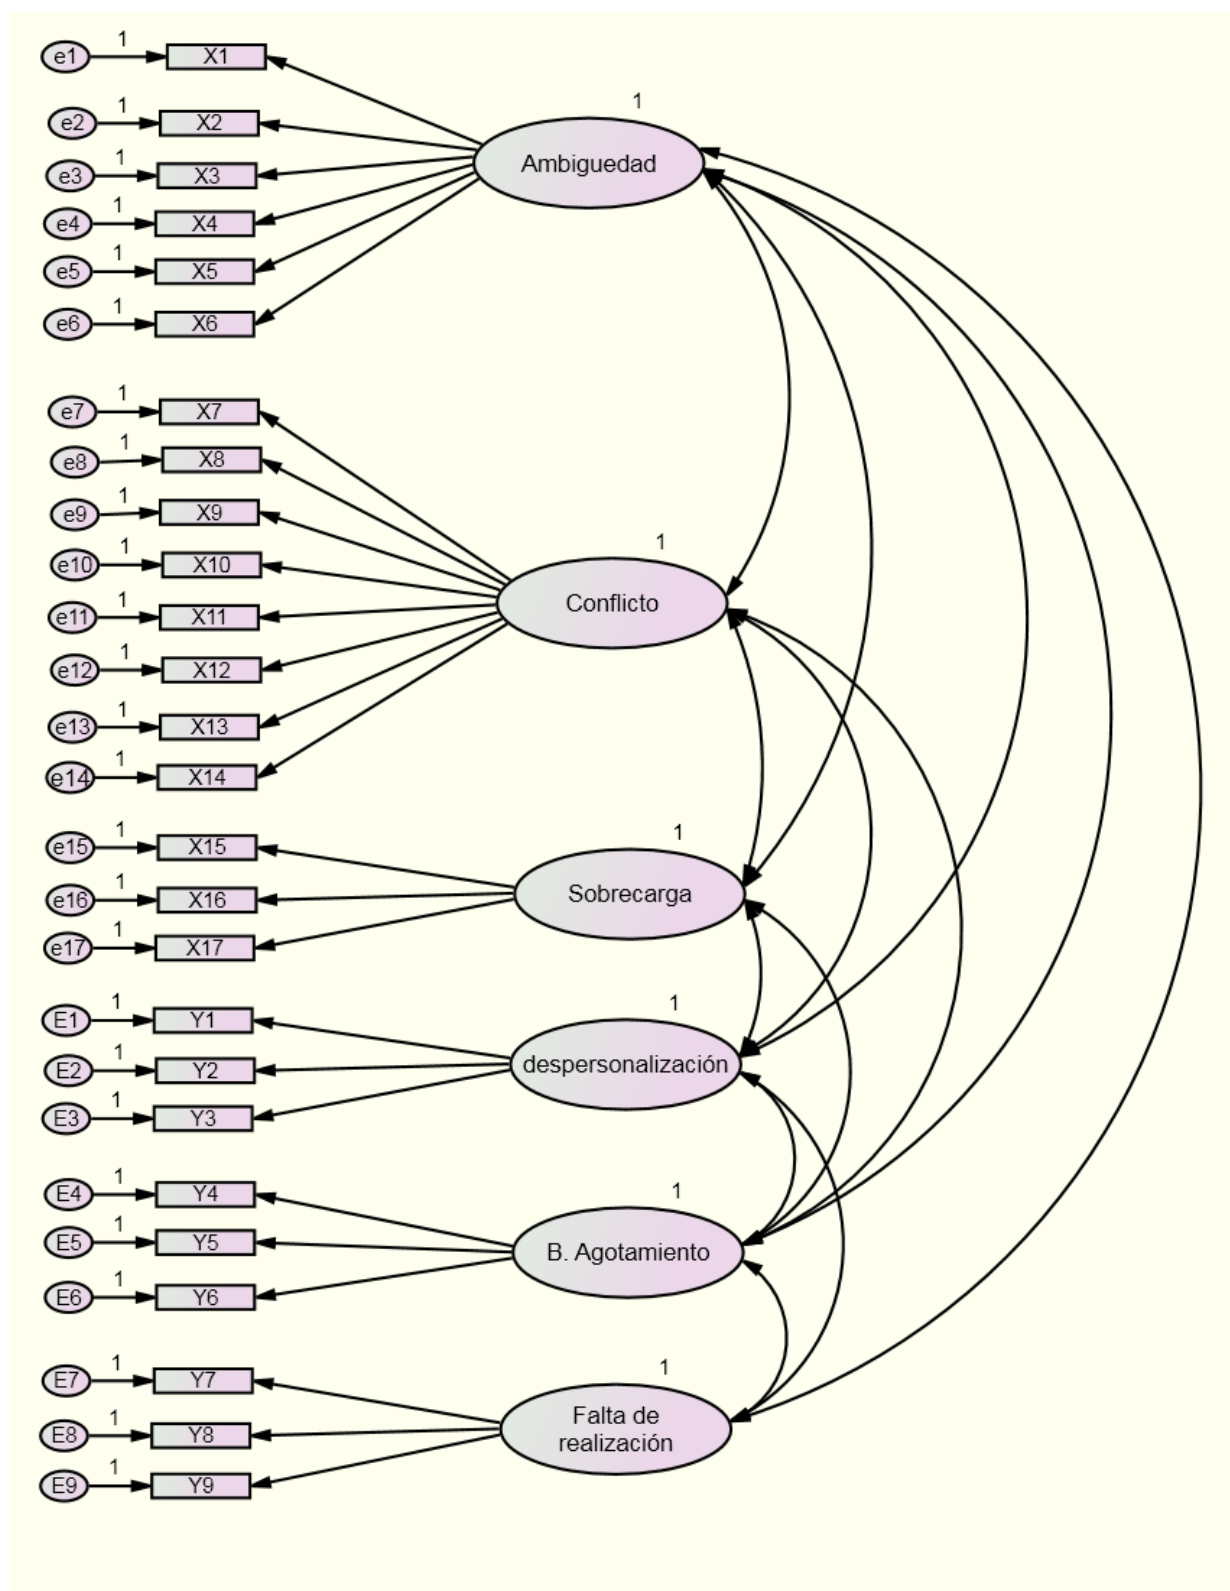
Tabla 2. Correlaciones entre las variables observables.

	x1	x2	x3	x4	x5	x6	x7	x8	x9	x10	x11	x12	x13	x14	x15	x16	x17	y1	y2	y3	y4	y5	y6	y7	y8	y9
x1	1																									
x2	0,579	1																								
x3	0,408	0,497	1																							
x4	0,634	0,625	0,506	1																						
x5	0,685	0,629	0,444	0,788	1																					
x6	0,557	0,691	0,421	0,711	0,689	1																				
x7	-0,047	-0,091	-0,018	0,002	0,005	-0,053	1																			
x8	-0,081	-0,162	-0,132	-0,027	-0,026	-0,118	0,442	1																		
x9	-0,124	-0,179	-0,097	-0,154	-0,129	-0,183	0,346	0,521	1																	
x10	-0,074	-0,139	-0,155	-0,108	-0,067	-0,129	0,328	0,333	0,412	1																
x11	-0,181	-0,224	-0,174	-0,147	-0,169	-0,261	0,330	0,463	0,467	0,576	1															
x12	-0,087	-0,178	-0,112	-0,138	-0,114	-0,203	0,255	0,423	0,456	0,471	0,626	1														
x13	-0,190	-0,250	-0,222	-0,158	-0,160	-0,238	0,338	0,623	0,537	0,398	0,595	0,548	1													
x14	-0,279	-0,380	-0,314	-0,310	-0,268	-0,359	0,273	0,317	0,384	0,336	0,472	0,425	0,514	1												
x15	-0,142	-0,127	-0,195	-0,102	-0,089	-0,158	1,000	0,277	0,258	0,331	0,342	0,253	0,379	0,315	1											
x16	-0,110	-0,087	-0,164	-0,052	-0,078	-0,139	0,220	0,294	0,203	0,293	0,361	0,218	0,363	0,286	0,801	1										
x17	-0,116	-0,127	-0,201	-0,072	-0,089	-0,155	0,164	0,268	0,170	0,244	0,319	0,220	0,311	0,264	0,750	0,814	1									
y1	-0,283	-0,224	-0,290	-0,336	-0,315	-0,275	0,059	0,049	0,183	0,212	0,227	0,209	0,185	0,269	0,224	0,235	0,235	1								
y2	-0,313	-0,228	-0,242	-0,329	-0,309	-0,296	0,031	0,057	0,196	0,129	0,214	0,162	0,201	0,289	0,165	0,178	0,165	0,800	1							
y3	-0,301	-0,235	-0,225	-0,258	-0,237	-0,211	0,035	0,115	0,197	0,146	0,210	0,139	0,200	0,247	0,161	0,184	0,156	0,603	0,754	1						
y4	-0,149	-0,047	-0,153	-0,059	-0,104	-0,171	0,026	0,101	0,034	0,191	0,208	0,077	0,143	0,131	0,435	0,500	0,523	0,243	0,187	0,165	1					
y5	-0,265	-0,189	-0,224	-0,239	-0,224	-0,301	0,132	0,157	0,131	0,207	0,255	0,177	0,301	0,255	0,372	0,449	0,413	0,252	0,242	0,205	0,612	1				
y6	-0,208	-0,128	-0,222	-0,126	-0,147	-0,216	0,051	0,205	0,176	0,206	0,292	0,175	0,315	0,280	0,474	0,522	0,479	0,307	0,299	0,324	0,576	0,621	1			
y7	0,398	0,349	0,306	0,423	0,349	0,339	-0,048	-0,064	-0,043	0,025	-0,063	-0,049	-0,104	-0,215	-0,050	-0,014	-0,051	-0,256	-0,289	-0,228	-0,097	-0,236	-0,199	1		
y8	0,385	0,292	0,263	0,403	0,296	0,266	-0,005	0,003	-0,059	0,003	0,008	0,008	-0,052	-0,197	-0,025	0,015	0,022	-0,257	-0,261	-0,221	0,056	-0,117	-0,135	0,670	1	
y9	0,378	0,300	0,368	0,376	0,345	0,277	0,043	-0,025	-0,079	-0,068	-0,108	-0,092	-0,059	-0,177	-0,143	-0,115	-0,106	-0,229	-0,246	-0,269	-0,033	-0,136	-0,241	0,524	0,501	1

Una de las variables indicadoras se creará a partir de las variables indicadoras referentes a la Ambigüedad de rol (ξ_1), otra variable indicadora será el Conflicto de rol (ξ_2) y Sobrecarga (ξ_3). Del mismo modo tenemos que las otras variables indicadoras que son la despersonalización (ξ_4), agotamiento emocional (ξ_5) y falta de realización personal(ξ_6).

En el grafico 9 podemos hacernos una idea más detallada de como se construyen las variables latentes a partir de las 26 variables observadas que entran en el modelo de ecuaciones estructurales inicial. Todas las relaciones existentes en el modelo se explicaran con detenimiento a continuación.

Figura 9. Modelo de ecuaciones estructurales.



2.2 Fiabilidad de escalas. Alpha de Cronbach.

En el análisis descriptivo de los datos es útil y necesario hacer hincapié en la fiabilidad de los datos para cuyo estudio se analiza el estadístico Alpha de Cronbach. Este estadístico supone un modelo de consistencia interna de los datos, que estima el límite inferior del coeficiente de fiabilidad basándose en el promedio de las correlaciones entre los ítems y cuyo cálculo viene determinado por la siguiente expresión:

$$\alpha = \left(\frac{K}{k-1} \right) \left(1 - \frac{\sum s_j^2}{s_{sum}^2} \right) \quad (16)$$

Donde k es el número de ítems de la escala o subescala, s_j^2 es la varianza de los ítems (desde 1,...,k) y s_{sum}^2 es la varianza de la escala total. Este coeficiente mide la fiabilidad de dicha escala en función de los términos: el número de ítems y la proporción de la varianza total de la prueba debida a la covarianza entre sus partes. La utilización de este estadístico ofrece la ventaja, de poder evaluar la fiabilidad del índice si se excluyera un determinado ítem, con el fin de poder predecir si mejoraría o empeoraría la fiabilidad de los datos. En la tabla 3 podemos observar los valores que obtiene cada uno de los índices, estos valores oscilan entre 0,786 obtenido en la escala total de los datos y el 0,918 obtenido en la escala de sobrecarga.

Tabla 3. Fiabilidad de escala Alpha de Cronbach.

	nº de ítems	Alpha de Cronbach
Ambigüedad	6	0,898
Conflicto	8	0,862
Sobrecarga	3	0,918
Despersonalización	3	0,877
Agotamiento emocional	3	0,819
Falta de realización	3	0,796
Total	26	0,786

En la tabla 4, tenemos la escala de fiabilidad, que se obtendría si eliminásemos los ítems (por escala). En el podemos observar como la escala de ambigüedad mejoraría su fiabilidad si eliminásemos el ítems X3 de 0,898 a 0,905. De la misma forma vemos que se mejoraría las escalas de la despersonalización y la falta de relación interpersonal eliminando los ítems Y3 e Y9 de 0,877 y 0,796 pasaría a ser de 0,883 0,802.

Tabla 4. Fiabilidad de las escalas eliminando los ítems.

	Media de la escala si se elimina el elemento	Varianza de la escala si se elimina el elemento	Correlación elemento-total corregida	Alfa de Cronbach si se elimina el elemento
X1	20,53	14,388	0,696	0,884
X2	20,74	13,535	0,742	0,877
X3	20,52	15,756	0,533	0,905
X4	20,48	13,388	0,814	0,866
X5	20,56	13,138	0,805	0,867
X6	20,82	12,853	0,760	0,875
X7	18,48	42,417	0,446	0,862
X8	19,03	39,002	0,619	0,844
X9	19,44	38,610	0,622	0,844
X10	19,03	39,175	0,564	0,851
X11	19,41	37,547	0,720	0,832
X12	19,08	37,744	0,644	0,841
X13	19,31	37,238	0,722	0,832
X14	19,40	40,023	0,535	0,853
X15	5,62	5,644	0,814	0,897
X16	5,60	5,476	0,864	0,857
X17	5,61	5,376	0,824	0,889
Y1	3,16	3,039	0,758	0,852
Y2	3,36	3,293	0,869	0,729
Y3	3,58	4,290	0,709	0,883

Y4	4,83	4,679	0,661	0,762
Y5	5,11	4,180	0,694	0,731
Y6	5,73	4,899	0,668	0,758
Y7	8,09	2,405	0,696	0,659
Y8	8,44	2,327	0,677	0,683
Y9	7,91	3,062	0,560	0,802

Además podemos ver en la tabla 5 podemos ver como mejoraría el índice de fiabilidad de la escala total si eliminamos los ítems de la escala de ambigüedad (X1, X2, X3, X4, X5, X6) y de la escala de falta de realización personal (Y7, Y8, Y9). Aunque en el mejor de los casos la mejoría de este índice que es 0,786 no llega a ser superior a 0,796.

Tabla 5. Fiabilidad de la escala total eliminando los ítems.

	Media de la escala si se elimina el elemento	Varianza de la escala si se elimina el elemento	Correlación elemento-total corregida	Alfa de Cronbach si se elimina el elemento
X1	75,94	128,806	0,023	0,791
X2	76,15	129,018	0,003	0,793
X3	75,93	130,538	-0,067	0,793
X4	75,89	127,326	0,090	0,789
X5	75,97	127,424	0,077	0,790
X6	76,23	130,118	-0,052	0,796
X7	76,74	120,591	0,343	0,778
X8	77,28	116,042	0,473	0,770
X9	77,70	116,619	0,433	0,773
X10	77,28	114,927	0,484	0,769
X11	77,66	113,574	0,567	0,765
X12	77,33	115,108	0,464	0,770
X13	77,57	113,493	0,555	0,765
X14	77,66	119,037	0,349	0,778
X15	77,34	113,766	0,562	0,765

X16	77,32	112,638	0,613	0,762
X17	77,33	113,498	0,545	0,766
Y1	78,25	122,367	0,240	0,783
Y2	78,44	124,081	0,215	0,784
Y3	78,67	124,895	0,229	0,783
Y4	77,13	118,343	0,397	0,775
Y5	77,42	118,267	0,360	0,777
Y6	78,03	117,700	0,453	0,772
Y7	76,01	127,641	0,068	0,790
Y8	76,35	126,240	0,126	0,788
Y9	75,83	128,641	0,036	0,790

2.3 Modelo de ecuaciones estructurales

Los componentes del modelo de ecuaciones estructurales son:

- Variables latentes ξ .
- Variables observadas X, Y .
- Errores de medidas ε .
- Los coeficientes de regresión λ_x, λ_y
- Coeficientes de covariación ϕ

Recordamos que un modelo de ecuaciones estructurales está compuesto por un modelo estructural y un modelo de medida. En este modelo de ecuaciones estructurales, solo tenemos el modelo de medida que quedara expresado mediante las ecuaciones:

$$\begin{array}{lll} X_1 = \lambda_{1,1}^x \xi_1 + \varepsilon_1 & X_{10} = \lambda_{10,2}^x \xi_2 + \varepsilon_{10} & Y_2 = \lambda_{2,4}^y \xi_4 + \varepsilon_{19} \\ X_2 = \lambda_{2,1}^x \xi_1 + \varepsilon_2 & X_{11} = \lambda_{11,2}^x \xi_2 + \varepsilon_{11} & Y_3 = \lambda_{3,4}^y \xi_4 + \varepsilon_{20} \\ X_3 = \lambda_{3,1}^x \xi_1 + \varepsilon_3 & X_{12} = \lambda_{12,2}^x \xi_2 + \varepsilon_{12} & Y_4 = \lambda_{4,5}^y \xi_5 + \varepsilon_{21} \\ X_4 = \lambda_{4,1}^x \xi_1 + \varepsilon_4 & X_{13} = \lambda_{13,2}^x \xi_2 + \varepsilon_{13} & Y_5 = \lambda_{5,5}^y \xi_5 + \varepsilon_{22} \\ X_5 = \lambda_{5,1}^x \xi_1 + \varepsilon_5 & X_{14} = \lambda_{14,2}^x \xi_2 + \varepsilon_{14} & Y_6 = \lambda_{6,5}^y \xi_5 + \varepsilon_{23} \\ X_6 = \lambda_{6,1}^x \xi_1 + \varepsilon_6 & X_{15} = \lambda_{15,3}^x \xi_3 + \varepsilon_{15} & Y_7 = \lambda_{7,6}^y \xi_6 + \varepsilon_{24} \\ X_7 = \lambda_{7,2}^x \xi_2 + \varepsilon_7 & X_{16} = \lambda_{16,3}^x \xi_3 + \varepsilon_{16} & Y_8 = \lambda_{8,6}^y \xi_6 + \varepsilon_{25} \\ X_8 = \lambda_{8,2}^x \xi_2 + \varepsilon_8 & X_{17} = \lambda_{17,3}^x \xi_3 + \varepsilon_{17} & Y_9 = \lambda_{9,6}^y \xi_6 + \varepsilon_{26} \\ X_9 = \lambda_{9,2}^x \xi_2 + \varepsilon_9 & Y_1 = \lambda_{1,4}^y \xi_4 + \varepsilon_{18} & \end{array}$$

Identificación del modelo

Para el modelo representado en el grafico anterior tenemos, que el número total de variables endógenas son $s = 26$, de forma que el número de elementos no redundantes la de matriz Σ es de $\frac{s(s+1)}{2} = 351$. Teniendo en este caso, que el número total de parámetros del modelo que tienen que estimarse es de $t = 45$.

Dado que t es estrictamente inferior a 351, se puede afirmar que el modelo se encuentra sobre-identificado, por lo que el modelo cumple la condición necesaria para estar identificado. Además puesto que no existe ninguna correlación entre los residuos, estamos ante un modelo recursivo.

Capítulo 3. Aplicación usando el programa AMOS.

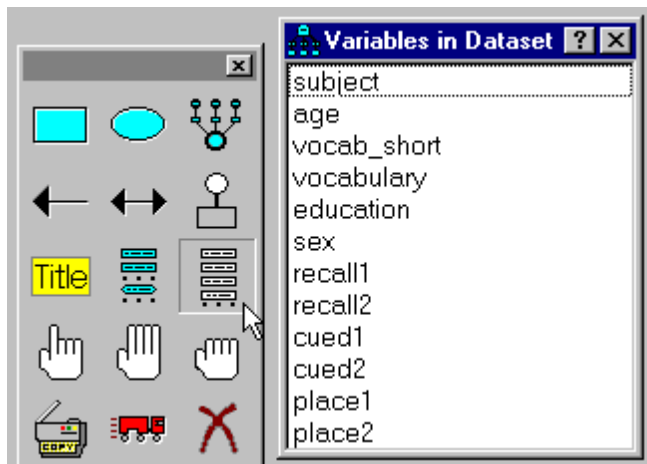
3.1 Especificación del modelo

Para estimar los modelos de ecuaciones estructurales utilizaremos el programa AMOS en la versión AMOS18.

Para poder estimar los modelos de ecuaciones estructurales mediante el programa AMOS, primero se ha de meter el modelo como en la figura 9, vista anteriormente. Hay que tener en cuenta que las variables dibujadas mediante circunferencias u óvalos representan las variables observables, y los representados mediante rectángulos son las variables observadas. Además, las variables correspondientes a los errores, que recordamos que en el capítulo 2 vimos que los errores no se representaban metidos en óvalos ni rectángulos. Pero al no ser observables, en el programa AMOS, estas variables se representan también como un ovalo, (estos óvalos se representan con un tamaño bastantes inferior al de las variables latentes).

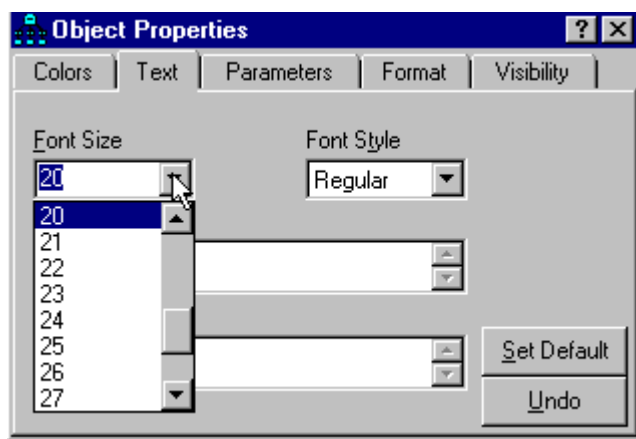
Para poder dibujar estas gráficas tenemos un menú, que podemos ver en la figura 10, en el que vemos la figuras de un rectángulo y un ovalo que representas estas variables comentadas anteriormente, así como las flechas, tanto bidireccionales como unidireccionales, que representan las covarianzas y las regresiones entre las variables, además de otras opciones como puede ser la opción de eliminar, seleccionar...

Figura10. Menú de opciones en AMOS.



También podemos cambiar las opciones de cada variable. Para ello hacemos doble clic sobre la variable (ya sea una variable observable o no observable) se muestra una ventana en la cual podemos cambiar el texto que muestra la variable, tamaño, el estilo de la fuente... Además nos da la opción de fijar una varianza para la variable (en la pestaña de Parameters).

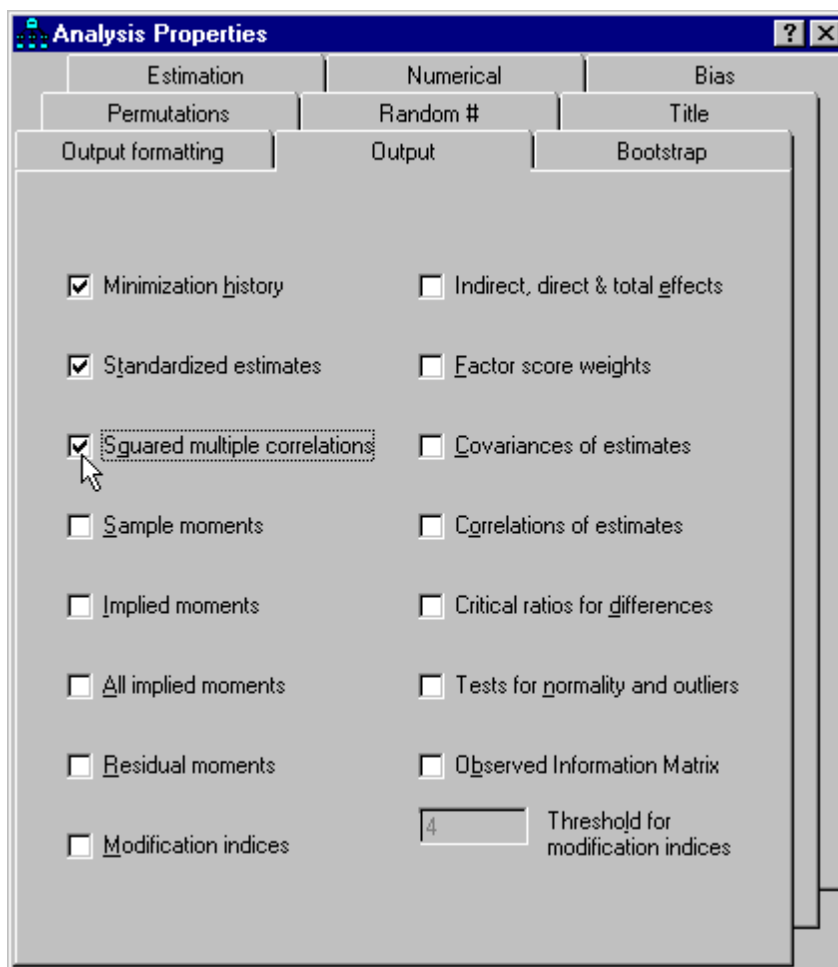
Figura 11. Menú de las variables en AMOS.



Una vez realizado el modelo, debemos de especificar las características para la estimación de los modelo. En la figura 12 podemos ver la ventana del menú analizar del programa. En la ventana de estimación podemos poner el método de estimación del modelo, ya sea el de máxima verosimilitud, Mínimos cuadrados ponderados o Mínimos

cuadrados generalizados. Entre las demás ventanas de opciones tenemos la pestaña Output, en ella podemos ver todas las opciones de salida que nos ofrece el programa, en ella podemos pedir la correlaciones, estimaciones de los parámetros así como diferentes opciones como test de normalidad o la matriz observada. Otra de las ventanas más importantes de este menú es la pestaña del bootstrap.

Figura 12. Ventana del menú Analizar del programa AMOS.



Antes de presentar los ajustes obtenidos, se han examinado todos los resultados buscando posibles coeficientes estimados que excedan los límites aceptables. Es decir, tenemos que comprobar que en los resultados de las estimaciones de los resultados no se cumplan ninguna de las condiciones siguientes:

- Varianzas de error negativas o varianzas de error no significativas.

- Coeficientes estandarizados cuyos valores sobrepasen 1.
- Errores estándar muy elevados asociados con cualquier coeficiente estimado.

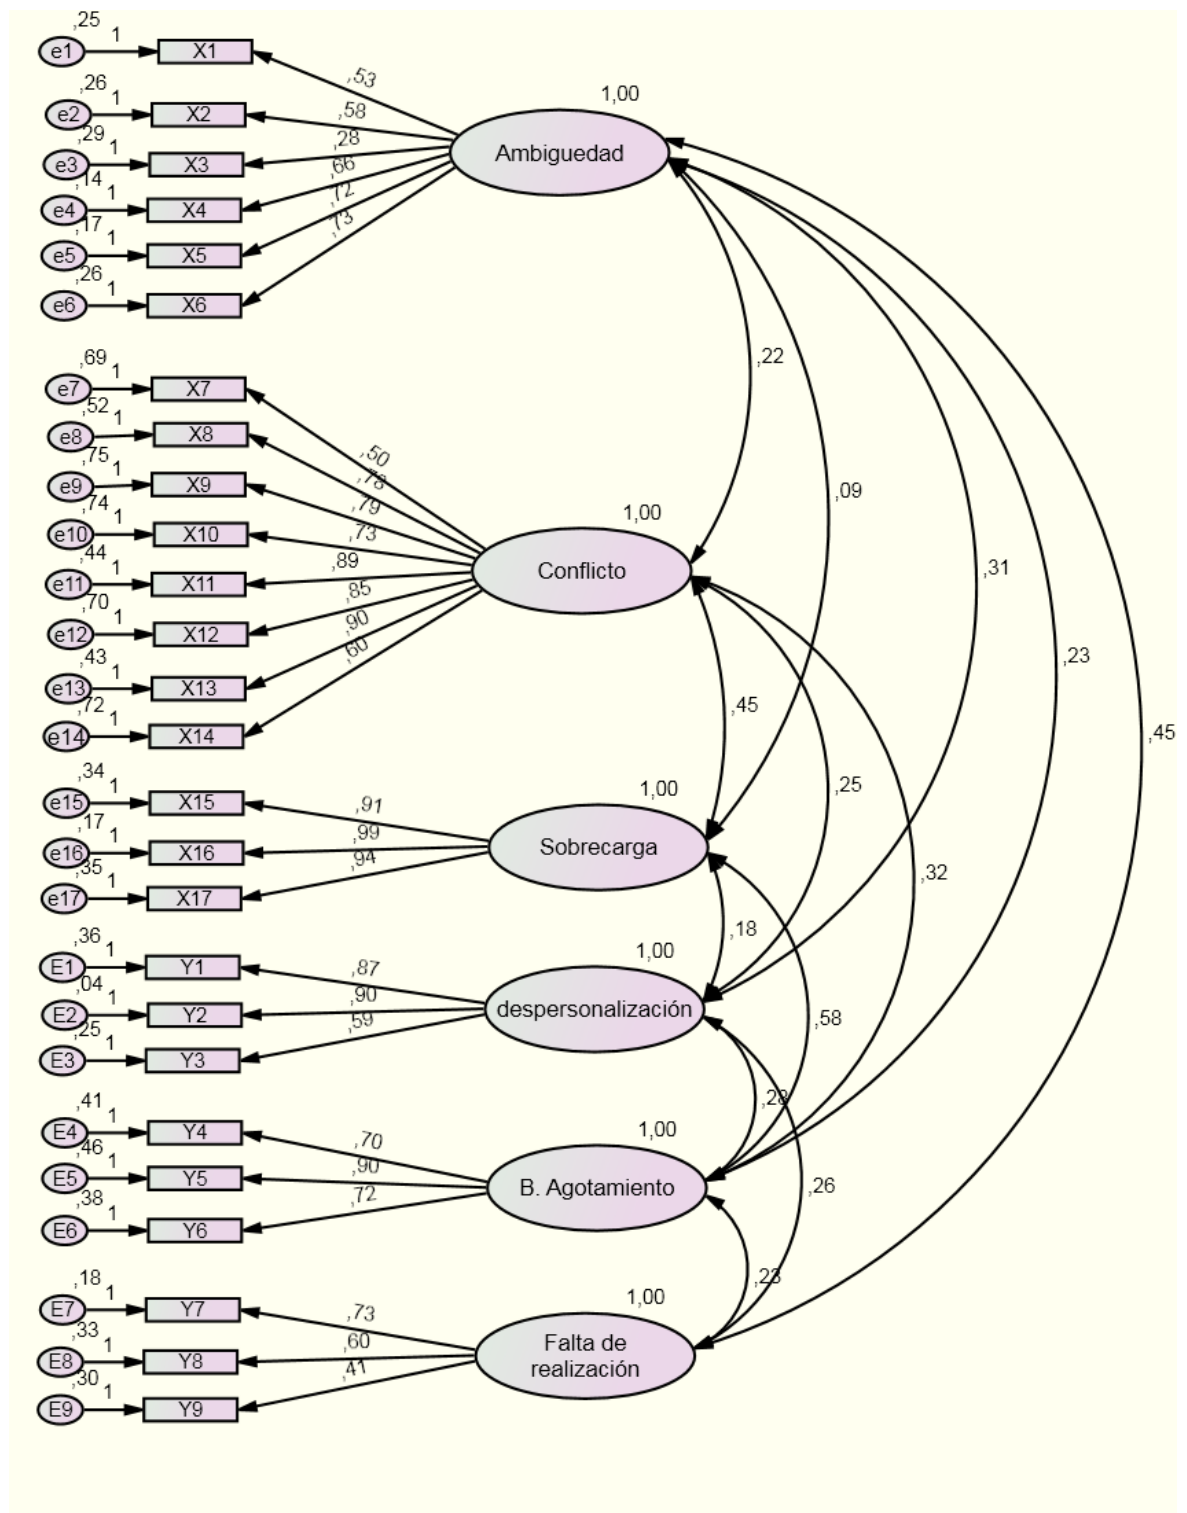
En los modelos originales se encontró que las covarianzas que relacionaban el conflicto y la sobrecarga de rol con la falta de realización personal se encontró que el era excesivo desechando de esa forma esas covariación del estudio.

3.2 Estimación del modelo en AMOS

En este punto comenzaremos en primer lugar, por estudiar y analizar el modelo inicial estima por el método de Mínimos cuadrados generalizados. Este método lo podemos utilizar porque, aunque se viola condición de normalidad multivariada, pero cumple la condición de normalidad univariada, este método se podía utilizar bajo las violaciones de estos supuestos. Este método es el más utilizado por la mayoría de autores, puesto que pocas veces los datos se ajustan bien a las condiciones de la hipótesis de la normalidad multivariante.

En el gráfico 10, tenemos el primer modelo, este modelo está están estimadas los 63 parámetros, todas ellas están estandarizadas para que la interpretación del modelo sea más sencilla.

Grafica 10. Modelo1 de ecuaciones estructurales por el método de Mínimos cuadrados generalizados.



Ahora tenemos que analizar el ajuste del modelo de medida, así que como las relaciones entre des distintas variables que conforman el modelo 1, partiendo de los distintos parámetros, estimados por Mínimos cuadrados generalizados, que aparecen reflejados en el Grafico 10. Los valores que aparecen junto a las fechas que van desde los constructos a las variables de medida indican la “carga factorial” de las variables indicadoras o directamente observables en el factor común. Tenemos el valor de la varianza explicada en la variable por el constructo (R^2), que podemos entender como la fiabilidad de la medida. Esta medida nos indica la cantidad de varianza del constructo que es explicada por el modelo. Falk y Miller (1992) señalan que la varianza explicada de las variables endógenas debería ser mayor o igual a 0,1. Los valores inferiores a 0,1 aun siendo significativos, proporcionan muy poca información. En la tabla 9, podemos ver como las variables con una varianza explicada mayor es y2, por tanto esta es la variable que aporta más información a su variable latente, despersonalización y la que menos información aporta es la variable x2 que aporta solo un 0,205.

Tabla 9. Varianza explicada por las variables observables por el método de los mínimos cuadrados generalizados.

Estimate		Estimate	
x1	0,534	x14	0,338
x2	0,563	x15	0,713
x3	0,205	x16	0,856
x4	0,755	x17	0,719
x5	0,753	y1	0,678
x6	0,668	y2	0,949
x7	0,262	y3	0,58
x8	0,535	y4	0,539
x9	0,455	y5	0,635
x10	0,422	y6	0,572
x11	0,639	y7	0,751
x12	0,508	y8	0,526
x13	0,654	y9	0,362

En la tabla 10, contiene las estimaciones de los parámetros del modelo, el error estándar aproximado, la proporción crítica y las estimaciones estandarizadas de los parámetros. La proporción crítica es el cociente entre la estimación del parámetro y la estimación del error estándar. Si se reúnen las suposiciones de distribución apropiadas, el estadístico sigue una distribución normal estándar bajo la hipótesis nula de que el parámetro tiene un valor de cero. Como se puede observar en la tabla todos los valores de proporción crítica son grandes, obteniendo de esta forma que todos los parámetros estimados son significativos

Tabla 10. Estimaciones de los parámetros.

			Estimate	S.	S.E.	C.R.	P
			Estimate				
x1	<---	Ambigüedad	0,531	0,731	0,041	12,999	***
x2	<---	Ambigüedad	0,577	0,75	0,045	12,834	***
x3	<---	Ambigüedad	0,275	0,453	0,04	6,883	***
x4	<---	Ambigüedad	0,657	0,869	0,039	16,657	***
x5	<---	Ambigüedad	0,722	0,868	0,042	17,238	***
x6	<---	Ambigüedad	0,726	0,817	0,048	15,221	***
x7	<---	Conflicto	0,496	0,512	0,058	8,489	***
x8	<---	Conflicto	0,776	0,731	0,06	12,89	***
x9	<---	Conflicto	0,794	0,675	0,063	12,569	***
x10	<---	Conflicto	0,733	0,65	0,065	11,23	***
x11	<---	Conflicto	0,888	0,8	0,058	15,371	***
x12	<---	Conflicto	0,849	0,712	0,065	13,126	***
x13	<---	Conflicto	0,901	0,809	0,058	15,442	***
x14	<---	Conflicto	0,605	0,581	0,062	9,703	***
x15	<---	Sobrecarga	0,912	0,844	0,055	16,64	***
x16	<---	Sobrecarga	0,991	0,925	0,052	19,172	***
x17	<---	Sobrecarga	0,945	0,848	0,057	16,643	***
y1	<---	despersonalización	0,866	0,824	0,053	16,234	***
y2	<---	despersonalización	0,902	0,974	0,042	21,313	***
y3	<---	despersonalización	0,586	0,762	0,04	14,82	***
y4	<---	Agotamiento	0,695	0,734	0,061	11,485	***
y5	<---	Agotamiento	0,899	0,797	0,066	13,616	***

y6	<---	Agotamiento	0,716	0,756	0,056	12,702	***
y7	<---	Falta de realización personal	0,73	0,866	0,049	14,842	***
y8	<---	Falta de realización personal	0,601	0,725	0,051	11,779	***
y9	<---	Falta de realización personal	0,41	0,602	0,043	9,536	***

Tabla 11. Estimación de los errores por el método de mínimos cuadrados generalizados.

	Estimate	S.E.	C.R.	P
x1	0,246	0,024	10,353	***
x2	0,259	0,027	9,672	***
x3	0,293	0,026	11,093	***
x4	0,14	0,017	8,042	***
x5	0,171	0,021	8,14	***
x6	0,262	0,029	8,983	***
x7	0,694	0,063	11	***
x8	0,523	0,056	9,279	***
x9	0,753	0,068	10,999	***
x10	0,735	0,072	10,2	***
x11	0,445	0,049	9,146	***
x12	0,699	0,068	10,346	***
x13	0,429	0,049	8,84	***
x14	0,717	0,067	10,706	***
x15	0,335	0,036	9,196	***
x16	0,166	0,03	5,516	***
x17	0,348	0,038	9,282	***
y1	0,356	0,041	8,604	***
y2	0,044	0,03	1,467	0,142
y3	0,248	0,025	10,049	***
y4	0,414	0,05	8,247	***
y5	0,464	0,067	6,922	***
y6	0,383	0,046	8,334	***
y7	0,177	0,045	3,972	***
y8	0,326	0,039	8,267	***
y9	0,297	0,029	10,1	***

Las correlaciones entre las variables latentes (representadas mediante las flechas bidireccionales), podemos ver en la gráfica 10 que son bastantes moderadas salvo la que representa la sobrecarga de rol con el agotamiento, con un valor de 0,58 y entre la ambigüedad de rol y la falta de realización personal además de el conflicto de rol y la sobrecarga , con un valor de 0,45 en ambos casos. La correlación más baja es de 0,09 que la podemos encontrar entre las variables de ambigüedad y la sobrecarga. En la tabla de los errores podemos ver como todos los errores son significativos salvo en y2, es decir, podemos suponer que en la variable 2 no se comete errores.

De este modo, el modelo de medida queda definido a través de las siguientes ecuaciones

$X_1 = 0,531\xi_1 + 0,246$	$X_{14} = 0,605\xi_2 + 0,717$
$X_2 = 0,577\xi_1 + 0,258$	$X_{15} = 0,912\xi_3 + 0,335$
$X_3 = 0,275\xi_1 + 0,293$	$X_{16} = 0,991\xi_3 + 0,166$
$X_4 = 0,657\xi_1 + 0,140$	$X_{17} = 0,945\xi_3 + 0,348$
$X_5 = 0,722\xi_1 + 0,171$	$Y_1 = 0,866\xi_4 + 0,356$
$X_6 = 0,726\xi_1 + 0,262$	$Y_2 = 0,902\xi_4 + 0,044$
$X_7 = 0,496\xi_2 + 0,694$	$Y_3 = 0,586\xi_4 + 0,248$
$X_8 = 0,776\xi_2 + 0,523$	$Y_4 = 0,695\xi_5 + 0,414$
$X_9 = 0,794\xi_2 + 0,753$	$Y_5 = 0,899\xi_5 + 0,464$
$X_{10} = 0,733\xi_2 + 0,735$	$Y_6 = 0,716\xi_5 + 0,383$
$X_{11} = 0,888\xi_2 + 0,523$	$Y_7 = 0,73\xi_6 + 0,177$
$X_{12} = 0,849\xi_2 + 0,699$	$Y_8 = 0,601\xi_6 + 0,326$
$X_{13} = 0,901\xi_2 + 0,429$	$Y_9 = 0,41\xi_6 + 0,297$

Estas ecuaciones definen el modelo de ecuaciones estructurales. Como se puede ver la primera variable latente, que es la Ambigüedad, está definida por las primeras seis variables observables y sus respectivos errores. Todas aportan una información parecida

a la escala, con valores de regresión entre 0,531 y 0,726 salvo la variable 3 que con un parámetro de regresión de 0,275 es la que aporta menos información. Además se tiene que los errores que se cometen en este grupo de variables ronda entre 0,140 y el 0,262.

La segunda variable latente, Conflicto, está definida por las siguientes ocho variables observables, estas variables tienen unos valores de regresión que 0,78 y 0,9 aportado la misma información, salvo la variable X7 que le aporta menos información con un valor de 0,5. Los errores en estas variables están comprendidos entre 0,43 y 0,72.

La tercera variable latente, Sobrecarga, la definen tres variables observables, cuyas valores de regresión van de 0,912 de la variable x15 hasta 0,991 de la variable x16. Teniendo estas variables unos errores entre de 0,166 y 0,348.

La cuarta variable latente, es la Despersonalización, los valores de las regresiones de estas variables oscilan entre 0,586 de la variable y3 y 0,902 de la variable y2. Los errores cometidos por las variables no son grande al estar entre 0,044 de la variable y2, siendo este el error más pequeño obtenido en las variables observables, y 0356 de la variable Y.

La quinta variables latente, Agotamiento, tiene unos valores de las regresiones asociadas que oscilan entre 0,695 y 0,899 de las variables y4 e y5, con unos errores asociados que van del 0,383 al 0,464 de las variables y6 e y5.

Y la última, la Falta de realización personal, sus regresiones oscilan entre 0,41 y 0,73 de las variables y9 e y7. Con unos errores situados entre 0,177 y 0,326.

En la tabla 12 podemos ver más claramente, todas las correlaciones existentes en el modelo. Además podemos ver como todos los parámetros son significativos salvo la correlación existente entre la ambigüedad y la sobrecargar que tiene un p- valor de 0,147. Estas correlaciones oscilan entre 0,219 de la correlación de la ambigüedad y el conflicto y 0,578 de la correlación entre el agotamiento y la ambigüedad.

Tabla 12, Tabla de las covarianzas por el método de los mínimos cuadrados generalizados

			Estimate	S.E.	C.R.	P
Ambigüedad	<-->	Conflicto	0,219	0,061	3,617	***
Ambigüedad	<-->	Sobrecarga	0,089	0,062	1,449	0,147
Conflicto	<-->	Sobrecarga	0,452	0,055	8,245	***
despersonalización	<-->	Agotamiento	0,28	0,065	4,34	***
despersonalización	<-->	Falta de realización	0,26	0,061	4,286	***
Agotamiento	<-->	Falta de realización	0,227	0,063	3,615	***
Ambigüedad	<-->	despersonalización	0,313	0,059	5,345	***
Conflicto	<-->	Agotamiento	0,32	0,066	4,846	***
Sobrecarga	<-->	despersonalización	0,175	0,06	2,899	0,004
Sobrecarga	<-->	Agotamiento	0,578	0,05	11,446	***
Ambigüedad	<-->	Agotamiento	0,233	0,071	3,278	0,001
Conflicto	<-->	despersonalización	0,252	0,059	4,288	***
Ambigüedad	<-->	Falta de realización	0,448	0,058	7,676	***

A continuación debemos analizar si el ajuste del modelo se confirma, esto se hace, llevando a cabo una evaluación global del mismo para determinar en qué medida el modelo reproduce adecuadamente las relaciones que existen en la matriz de covarianzas de los datos. En modelo tiene 286 grados de libertad y un valor de Chi Cuadrado de 495,475 donde este estadístico tiene asociado una probabilidad asociada menor de 0,000 por lo que, este estadístico tiene un valor significativo. Aunque este estadístico no es fiables, (como ya se explico en el capítulo 2), es muy sensible al número de la muestra y a la no normalidad multivariante de los dato. Como la muestra es de 349 que es superior a 200 y no cumplir la normalidad multivariante, hacen que este índice se tome como una medida orientativa.

El siguiente paso del análisis, tenemos que ver los índices de bondad de ajuste del modelo para comprobar si el ajuste del modelo propuesto es aceptable. El programa AMOS nos muestra varios índices, pero solo vamos a interpretar los índices expuestos en el capítulo 2 que son los más utilizados por los diversos autores.

Tabla 13. Índices de bondad de ajuste

Medida de ajuste	Default model	saturated model	Independence model
NFI	0,547	1	0
NNFI	0,69		0
CFI	0,728	1	0
GFI	0,89	0	0,758
RMSEA	0,046		0,082
LO 90	0,039		0,077
HI 90	0,053		0,088
SRMR	0,078		

Con la relación de los índices absolutos obtenidos, tenemos que este modelo inicial propuesto es bastante pobre y no se ajustan bien a los datos. Como se puede observar en la tabla 12 se tiene que el valor del NFI=0,547, este valor es muy inferior a 0,9 que es el valor que los autores consideran mínimo para los diversos autores. Del mismo modo sucede con los valores de los estadísticos NNFI y CFI cuyos valores 0,69 y 0,728 son inferiores a los valores mínimos exigidos para un buen modelo del ajuste, y también el valor del estadísticos del GFI que es de 0,89 está al límite del valor mínimo esperado que es de 0,9. El valor del estadístico RMSEA es el único que cumple con crece las expectativas de un buen modelo, es decir, el valor del estadístico 0,046 es inferior a 0,08 que es el valor máximo esperado para este índice, además el intervalo superior del RMSEA al 90% es de 0,53 que sigue siendo inferior a 0,08. Y por último se tiene que el valor del SRMR es 0,078 siendo este superior a 0,05 que es el valor mínimo esperado para el ajuste de un buen modelo.

A veces resulta que un modelo no se ajusta bien para un determinado método de estimación, pero podemos estudiar el mismo modelo por otros métodos donde, a veces, estos modelos se ajustan perfectamente a los datos.

Por este motivo, para completar este análisis, vamos a estimar los parámetros del modelo con el método de estimación de máxima verosimilitud, podemos estimar el modelo por este método al cumplirse la normalidad univariante de las variables, aunque

no se cumpla la normalidad multivariante de ellas. No podemos estimar el modelo por el método de Mínimos cuadrados ponderados, puesto que el número de datos que tenemos es insuficiente para poder estimarlo y si lo intentásemos estimar el programa nos mostraría un mensaje de error.

Grafica 11. Modelo de ecuaciones estructurales estimados por el método de la máxima verosimilitud.

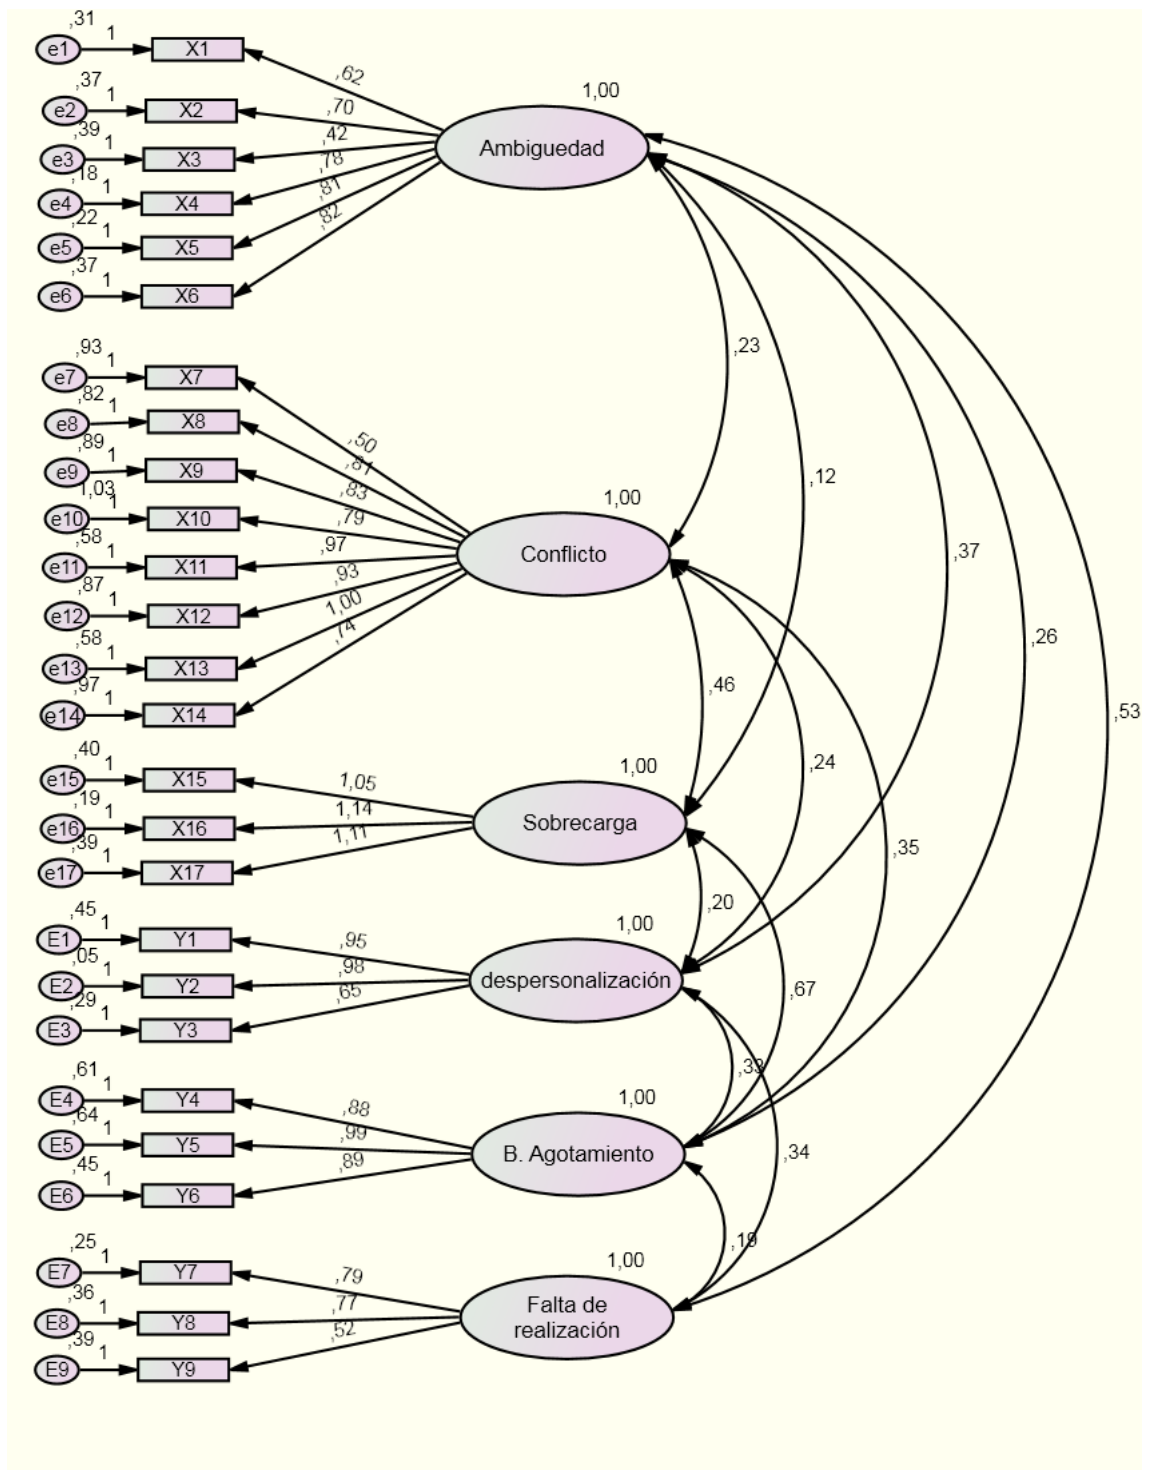


Tabla 14. Medidas de ajustes para el método de estimación de máxima verosimilitud.

Medida de ajuste	Default model	saturated model	Independence model
NFI	0,886	1	0
NNFI	0,927		0
CFI	0,935	1	0
GFI	0,881	0	0,758
RMSEA	0,057		0,211
LO 90	0,051		0,206
HI 90	0,063		0,216
SRMR	0,0662		

En la tabla 14 podemos ver las medidas de ajustes para el método de estimación de máxima verosimilitud. En esta tabla, y al contrario de lo que ocurría con el otro método de estimación, tenemos que la mayoría de los estimadores están, o dentro del rango esperado, o muy cercano a él. Es decir, vemos como el estadístico de NNFI y CFI son 0,927 y 0,935 que son valores superiores al valor mínimo esperado que era de 0,9. Además los estadísticos NFI y GFI cuyos valores son 0,886 y de 0,881 son valores inferiores al valor mínimo esperado por estos valores que es 0,9 pero al estar cercanos a este valor podemos decir que estos índices no nos indican un mal ajuste del modelo. Además, tenemos el valor del RMSEA, así como su valor para el intervalo superior Hi 90 son inferiores al valor máximo esperado 0,08. El valor de SRMR es de 0,0662, como comentamos este valor es superior al valor máximo esperado que es de 0,05. Aun así este término tiene un poco de discrepancia y hay muchos autores que consideran esta valor adecuado para valores inferiores a 0,08. De esta forma, podemos afirmar con todos estos datos anteriores que la estimación del modelo por el método de máxima verosimilitud es aceptable. Solamente queda observar que los datos no siguen una distribución normal multivariante, no afecta a la capacidad del método para estimar de forma no sesgada los parámetros del modelo. Pasamos de esta forma a ver los parámetros del modelo.

Tabla 15. Estimación de los parámetros por el método de máxima verosimilitud.

			Estimate	S.	S.E.	C.R.	P
			Estimate				
x1	<---	Ambigüedad	0,622	0,745	0,039	15,925	***
x2	<---	Ambigüedad	0,703	0,755	0,043	16,233	***
x3	<---	Ambigüedad	0,421	0,559	0,038	10,963	***
x4	<---	Ambigüedad	0,779	0,877	0,038	20,403	***
x5	<---	Ambigüedad	0,809	0,865	0,041	19,965	***
x6	<---	Ambigüedad	0,823	0,804	0,046	17,789	***
x7	<---	Conflicto	0,499	0,459	0,058	8,556	***
x8	<---	Conflicto	0,81	0,666	0,061	13,345	***
x9	<---	Conflicto	0,827	0,658	0,063	13,161	***
x10	<---	Conflicto	0,787	0,612	0,066	11,989	***
x11	<---	Conflicto	0,967	0,787	0,058	16,786	***
x12	<---	Conflicto	0,931	0,707	0,064	14,462	***
x13	<---	Conflicto	0,998	0,794	0,059	17,016	***
x14	<---	Conflicto	0,741	0,601	0,063	11,729	***
x15	<---	Sobrecarga	1,049	0,857	0,054	19,605	***
x16	<---	Sobrecarga	1,136	0,934	0,05	22,516	***
x17	<---	Sobrecarga	1,112	0,873	0,055	20,158	***
y1	<---	despersonalización	0,954	0,819	0,053	18,052	***
y2	<---	despersonalización	0,977	0,973	0,042	23,504	***
y3	<---	despersonalización	0,65	0,769	0,039	16,56	***
y4	<---	Agotamiento	0,88	0,747	0,058	15,171	***
y5	<---	Agotamiento	0,993	0,778	0,062	16,006	***
y6	<---	Agotamiento	0,888	0,797	0,054	16,544	***
y7	<---	Falta de realización personal	0,788	0,843	0,046	17,143	***
y8	<---	Falta de realización	0,769	0,787	0,049	15,762	***

		personal					
y9	<---	Falta de realización personal	0,515	0,637	0,042	12,199	***

Tabla 16. Estimaciones de los errores mediante el método de máxima verosimilitud.

	Estimate	S.E.	C.R.	P
x1	0,31	0,026	11,749	***
x2	0,372	0,032	11,656	***
x3	0,391	0,031	12,673	***
x4	0,183	0,02	9,295	***
x5	0,22	0,023	9,695	***
x6	0,371	0,034	11,068	***
x7	0,931	0,073	12,728	***
x8	0,825	0,07	11,807	***
x9	0,893	0,075	11,859	***
x10	1,034	0,085	12,152	***
x11	0,576	0,056	10,343	***
x12	0,866	0,076	11,445	***
x13	0,584	0,057	10,198	***
x14	0,972	0,08	12,209	***
x15	0,397	0,039	10,145	***
x16	0,188	0,031	6,028	***
x17	0,387	0,04	9,596	***
y1	0,447	0,044	10,178	***
y2	0,053	0,029	1,83	0,067
y3	0,291	0,026	11,335	***
y4	0,612	0,061	9,975	***
y5	0,643	0,069	9,264	***
y6	0,452	0,052	8,725	***
y7	0,253	0,04	6,346	***
y8	0,363	0,044	8,31	***
y9	0,389	0,034	11,362	***

En la tabla16 podemos ver como todos los errores son significativos salvo en y2, es decir, podemos suponer que en la variable 2 no se comete errores. Con las tablas anteriores podemos construir las ecuaciones del modelo:

$X_1 = 0,622\xi_1 + 0,310$	$X_{10} = 0,787\xi_2 + 1,034$	$Y_2 = 0,977\xi_4 + 0,053$
$X_2 = 0,703\xi_1 + 0,372$	$X_{11} = 0,967\xi_2 + 0,576$	$Y_3 = 0,650\xi_4 + 0,291$
$X_3 = 0,421\xi_1 + 0,391$	$X_{12} = 0,931\xi_2 + 0,866$	$Y_4 = 0,880\xi_5 + 0,612$
$X_4 = 0,779\xi_1 + 0,183$	$X_{13} = 0,998\xi_2 + 0,584$	$Y_5 = 0,993\xi_5 + 0,643$
$X_5 = 0,809\xi_1 + 0,220$	$X_{14} = 0,741\xi_2 + 0,972$	$Y_6 = 0,888\xi_5 + 0,452$
$X_6 = 0,823\xi_1 + 0,371$	$X_{15} = 0,857\xi_3 + 0,397$	$Y_7 = 0,788\xi_6 + 0,253$
$X_7 = 0,499\xi_2 + 0,931$	$X_{16} = 1,136\xi_3 + 0,188$	$Y_8 = 0,769\xi_6 + 0,363$
$X_8 = 0,810\xi_2 + 0,825$	$X_{17} = 1,112\xi_3 + 0,387$	$Y_9 = 0,515\xi_6 + 0,253$
$X_9 = 0,827\xi_2 + 0,893$	$Y_1 = 0,954\xi_4 + 0,447$	

De esta forma, las ecuaciones anteriores definen el modelo de ecuaciones estructurales. En estas ecuaciones, son muy parecidas a las obtenidas por el método de los mínimos cuadrados generalizados. En este método tenemos que las regresiones son algo más altas, oscilando entre 0,421 y 1,136 de las variables x_3 y x_{16} . Las variables con los errores más altas están en la segunda variable latente, Conflicto, con errores que van desde 0,825 hasta 1,034, obtenidas en las variables x_8 y x_{10} , y las demás variables los errores no superan el 0,7.

Las correlaciones entre las variables latentes (representadas mediante las flechas bidireccionales), podemos ver en la gráfica 10 y en la tabla 17 que oscilan entre 0,121 de la correlación entre la ambigüedad y la sobrecarga y la correlación de 0,668 entre las variables sobrecarga y agotamiento. Además cabe resaltar que todas son significativas, aunque hay una correlación entre la ambigüedad y la sobrecarga que tiene un p valor de 0,017 pero este es menor que 0,05 y por tanto tenemos que es significativa.

Tabla 17. Tabla de las covarianzas por el método de los máxima verosimilitud.

			Estimate	S.E.	C.R.	P
Ambigüedad	<->	Conflicto	0,235	0,05	4,668	***
Ambigüedad	<-->	Sobrecarga	0,121	0,051	2,376	0,017
Conflicto	<-->	Sobrecarga	0,46	0,048	9,571	***
despersonalización	<-->	Agotamiento	0,331	0,054	6,128	***
despersonalización	<-->	Falta de realización	0,339	0,053	6,432	***
Agotamiento	<-->	Falta de realización	0,192	0,051	3,736	***
Ambigüedad	<-->	despersonalización	0,374	0,05	7,557	***
Conflicto	<-->	Agotamiento	0,35	0,056	6,246	***
Sobrecarga	<-->	despersonalización	0,199	0,052	3,797	***
Sobrecarga	<-->	Agotamiento	0,668	0,038	17,7	***
Ambigüedad	<-->	Agotamiento	0,257	0,056	4,564	***
Conflicto	<-->	despersonalización	0,237	0,053	4,476	***
Ambigüedad	<-->	Falta de realización	0,531	0,046	11,621	***

Capítulo 4. Aplicación usando R.

4.1 Especificación del modelo.

En R tenemos que existen varios paquetes para poder realizar el análisis de ecuaciones estructurales. Unos de estos paquetes que actualmente está más desarrollado es el paquete lavaan (Rosseel 2011), puesto que permite desarrollar modelos de estructura y de medidas más sencillamente que los demás paquetes, y permite realizar análisis con el uso de métodos de estimaciones alternativos como el método de máxima verosimilitud robusto o el mínimos cuadrados generalizados diagonalizados que están desarrollados para salvar las limitaciones de los otros métodos.

Las referencias para la sintaxis de especificación de los modelos en lavaan son el texto introductorio de Rosseel (2011) y el manual de referencia (Rosseel, 2012b).

Para introducir el modelo de la figura 9, la sintaxis que debemos de introducir es:

```
Modelo <-  
'Ambiguedad=~ x1+x2+x3+x4+x5+x6  
conflicto =~ x7+x8+x9+x10+x12+x13+x14  
Sobrecarga=~ x15+x16+x17  
'despersonalizacion=~ y1+y2+y3  
Agotamiento=~ y4+y5+y6  
FaltaRealizacion=~ y7+y8+y9'
```

En esta sintaxis, hay que remarcar, que las relaciones de regresiones se utilizan el comando =~ cuando definen una variable latente y ~ cuando la relacion es entre dos variables observables, y para las relaciones de covarianzas se utiliza el comando Es decir:

Variable latente =~

Regresión ~

Varianza y covarianza ~~

Además el paquete Lavaan automáticamente relaciona las variables latentes con relaciones de covarianzas, con lo que utilizaríamos el comando `~~` cuando queramos hacer relaciones de covarianzas entre variables latentes (estas relaciones no la tenemos en nuestro modelo). Es decir, en el modelo anterior, no tenemos ninguna relación de covariación definida, tenemos que el modelo es equivalente al siguiente modelo:

```
Modelo2 <-
'Ambigüedad=~ x1+x2+x3+x4+x5+x6
conflicto =~ x7+x8+x9+x10+x12+x13+x14
Sobrecarga=~ x15+x16+x17
'despersonalizacion=~ y1+y2+y3
Agotamiento=~ y4+y5+y6
FaltaRealizacion=~ y7+y8+y9

Ambigüedad ~~ conflicto + Sobrecarga+ despersonalizacion + Agotamiento +
FaltaRealizacion
conflicto ~~ Sobrecarga+ despersonalizacion + Agotamiento + FaltaRealizacion
Sobrecarga~~ despersonalizacion + Agotamiento + FaltaRealizacion
despersonalizacion ~~ Agotamiento + FaltaRealizacion
Agotamiento ~~ FaltaRealizacion '
```

4.1 Estimación de modelos en R

En R, el paquete lavaan dispone de tres funciones para estimar los modelos de ecuaciones estructurales: `sem`, `cfa` y `lavaan`. La función `cfa` esta dedicada al análisis factorial confirmatorio, la función `lavaan` también permite estimar modelos genéricos de ecuaciones estructurales, en los que se especifica el modelo completo, y en `sem` estima los modelos estructurales genéricos. En `sem` se tiene que especificar primero el modelo, y después la fuente de los datos, si bien, podemos utilizar tanto los datos originales, como la matriz de covarianzas y el número de observaciones. A continuación se debe de introducir el de estimación por el que queramos estimar el modelo de ecuaciones estructurales mediante el comando “estimator”, el cual debemos de utilizar ML para el

método de máxima verosimilitud, GLS para el de mínimos cuadrados generalizados, WLS para el método del mínimos cuadrados ponderados, así como cualquier otro método que se están extendiendo en la mayoría de los autores por su efectividad como son el MLR (máxima verosimilitud robusto) o DWLS (mínimos cuadrados ponderados diagonalizados) entre otros. Para poder ver todo el listado de indicadores del ajuste del modelo, podemos ejecutar el comando, Fit.measures=TRUE. El paquete lavaan tiene algunas limitaciones, en comparación con el programa AMOS, lavaan no nos aporta una gran cantidad de estadísticos de bondad de ajustes. Así, en AMOS solo utilizamos algunos de los estadísticos que nos ofrecían, en lavaan solo ofrecen los estadísticos mas característicos, que son el NNFI, CFI, RMSEA, SRMR, el AIC y el BIC.

Por tanto vamos a estimar la figura 9, por el método mínimos cuadrados ponderados y el de máxima verosimilitud, que vimos en el capítulo anterior que era el más conveniente para este conjunto de datos. Suponiendo que los datos están introducidos ya en el programa mediante el nombre Datos, tenemos que realizar los siguientes comandos, para el método de los mínimos cuadrados ponderados:

Library (lavaan)

Modelo <-

'Ambigüedad= ~ x1+x2+x3+x4+x5+x6

conflicto = ~ x7+x8+x9+x10+x11+x12+x13+x14

Sobrecarga= ~ x15+x16+x17

despersonalizacion= ~ y1+y2+y3

Agotamiento= ~ y4+y5+y6

FaltaRealizacion= ~ y7+y8+y9 '

Ajuste <- sem(Modelo, data=Datos, estimator="GLS")

Y para mostrar los resultados realizaremos la sintaxis:

lavaan (0.5-16) converged normally after 64 iterations

<i>Number of observations</i>	<i>349</i>
<i>Estimator</i>	<i>GLS</i>
<i>Minimum Function Test Statistic</i>	<i>495.199</i>
<i>Degrees of freedom</i>	<i>284</i>
<i>P-value (Chi-square)</i>	<i>0.000</i>

Model test baseline model:

<i>Minimum Function Test Statistic</i>	1093.837
<i>Degrees of freedom</i>	325
<i>P-value</i>	0.000

User model versus baseline model:

<i>Comparative Fit Index (CFI)</i>	0.725
<i>Tucker-Lewis Index (TLI)</i>	0.686

Root Mean Square Error of Approximation:

<i>RMSEA</i>	0.046
<i>90 Percent Confidence Interval</i>	0.039 0.053
<i>P-value RMSEA <= 0.05</i>	0.818

Standardized Root Mean Square Residual:

<i>SRMR</i>	0.124
-------------	-------

Parameter estimates:

<i>Information</i>	<i>Expected</i>
<i>Standard Errors</i>	<i>Standard</i>

	<i>Estimate</i>	<i>Std.err</i>	<i>Z-value</i>	<i>P(> z)</i>	<i>Std.lv</i>	<i>Std.all</i>
<i>Latent variables:</i>						
<i>Ambigüedad =~</i>						
<i>x1</i>	1.000			0.537	0.734	
<i>x2</i>	1.098	0.095	11.542	0.000	0.589	0.756
<i>x3</i>	0.529	0.076	6.940	0.000	0.284	0.464
<i>x4</i>	1.232	0.093	13.279	0.000	0.661	0.870
<i>x5</i>	1.349	0.095	14.200	0.000	0.724	0.868
<i>x6</i>	1.379	0.116	11.922	0.000	0.740	0.822
<i>conflicto =~</i>						
<i>x7</i>	1.000			0.495	0.510	
<i>x8</i>	1.563	0.188	8.325	0.000	0.774	0.730
<i>x9</i>	1.609	0.206	7.811	0.000	0.796	0.676
<i>x10</i>	1.475	0.196	7.520	0.000	0.730	0.647
<i>x11</i>	1.810	0.228	7.932	0.000	0.896	0.802
<i>x12</i>	1.724	0.234	7.380	0.000	0.853	0.714
<i>x13</i>	1.838	0.232	7.927	0.000	0.910	0.811
<i>x14</i>	1.275	0.185	6.907	0.000	0.631	0.597
<i>Sobrecarga =~</i>						
<i>x15</i>	1.000			0.916	0.845	
<i>x16</i>	1.084	0.056	19.247	0.000	0.993	0.925
<i>x17</i>	1.035	0.059	17.621	0.000	0.948	0.849
<i>despersonalizacion =~</i>						

y1	1.000			0.875	0.826	
y2	1.036	0.058	17.881	0.000	0.906	0.973
y3	0.675	0.046	14.684	0.000	0.591	0.764
Agotamiento =~						
y4	1.000			0.694	0.732	
y5	1.312	0.126	10.407	0.000	0.911	0.801
y6	1.043	0.101	10.311	0.000	0.724	0.760
FaltaRealizacion =~						
y7	1.000			0.737	0.870	
y8	0.813	0.081	9.981	0.000	0.599	0.723
y9	0.561	0.066	8.523	0.000	0.413	0.604

Covariances:

Ambigüedad ~~

conflicto	-0.068	0.021	-3.310	0.001	-0.256	-0.256
Sobrecarga	-0.054	0.035	-1.564	0.118	-0.110	-0.110
despersonalizcn	-0.152	0.036	-4.285	0.000	-0.324	-0.324
Agotamiento	-0.095	0.031	-3.090	0.002	-0.254	-0.254
FaltaRealizcn	0.181	0.034	5.286	0.000	0.458	0.458

conflicto ~~

Sobrecarga	0.208	0.041	5.065	0.000	0.459	0.459
despersonalizcn	0.118	0.032	3.720	0.000	0.273	0.273
Agotamiento	0.116	0.029	4.035	0.000	0.338	0.338
FaltaRealizcn	-0.017	0.026	-0.653	0.514	-0.047	-0.047

Sobrecarga ~~

despersonalizcn	0.149	0.055	2.735	0.006	0.186	0.186
Agotamiento	0.369	0.062	5.942	0.000	0.580	0.580
FaltaRealizcn	-0.017	0.048	-0.346	0.729	-0.025	-0.025

despersonalizacion ~~

Agotamiento	0.177	0.048	3.729	0.000	0.292	0.292
FaltaRealizcn	-0.175	0.046	-3.779	0.000	-0.271	-0.271

Agotamiento ~~

FaltaRealizcn	-0.128	0.041	-3.129	0.002	-0.249	-0.249
---------------	--------	-------	--------	-------	--------	--------

Variances:

x1	0.246	0.024		0.246	0.461	
x2	0.260	0.027		0.260	0.428	
x3	0.294	0.027		0.294	0.785	
x4	0.141	0.017		0.141	0.244	
x5	0.172	0.021		0.172	0.247	
x6	0.262	0.029		0.262	0.324	
x7	0.696	0.063		0.696	0.740	
x8	0.525	0.056		0.525	0.467	
x9	0.756	0.069		0.756	0.544	
x10	0.738	0.072		0.738	0.581	
x11	0.446	0.049		0.446	0.357	
x12	0.702	0.068		0.702	0.491	
x13	0.430	0.049		0.430	0.342	
x14	0.717	0.067		0.717	0.643	

<i>x15</i>	0.336	0.037	0.336	0.286
<i>x16</i>	0.166	0.030	0.166	0.144
<i>x17</i>	0.349	0.038	0.349	0.280
<i>y1</i>	0.355	0.041	0.355	0.317
<i>y2</i>	0.046	0.030	0.046	0.053
<i>y3</i>	0.248	0.025	0.248	0.416
<i>y4</i>	0.416	0.050	0.416	0.464
<i>y5</i>	0.463	0.067	0.463	0.358
<i>y6</i>	0.384	0.046	0.384	0.423
<i>y7</i>	0.175	0.045	0.175	0.244
<i>y8</i>	0.328	0.039	0.328	0.478
<i>y9</i>	0.298	0.029	0.298	0.635
<i>Ambigüedad</i>	0.288	0.044	1.000	1.000
<i>conflicto</i>	0.245	0.058	1.000	1.000
<i>Sobrecarga</i>	0.839	0.101	1.000	1.000
<i>despersonlzcñ</i>	0.765	0.094	1.000	1.000
<i>Agotamiento</i>	0.481	0.084	1.000	1.000
<i>FaltaRealizcn</i>	0.543	0.073	1.000	1.000

Obteniendo los resultados siguientes que compararemos con los obtenidos en AMOS:

Tabla 18. Comparación de los resultados de bondad de ajuste entre R y AMOS, por el método de mínimos cuadrados generalizados.

Medida de ajuste	Modelo R	Modelo AMOS
NNFI	0,686	0,690
CFI	0,725	0,728
RMSEA	0,046	0,046
LO 90	0.039	0,039
HI 90	0.053	0,053
SRMR	0.124	0,078

En la tabla 19 se puede ver como los estadísticos de bondad de ajuste son prácticamente iguales, no habiendo diferencias significativas entre ambos programas salvo en el estimador SRMR que tiene un valor de 0,124, de forma que este modelo no sería aceptable mediante la estimación de mínimos cuadrados generalizados. Estas diferencias se deben a que en Lavaan no podemos fijar las varianzas iniciales y por defecto tomo como 1 las regresiones entre las variables latentes y la primera variable observable con la que está definida, es decir, en la tabla 18 vemos como cada variable

latente tiene, como parámetro de regresión, con la primera variable observable, el valor 1.

Tabla 19. Parámetros estimados por el método de mínimos cuadrados generalizados en R.

		Estimate	Std.err	Z-value	P(> z)	Std.lv	Std.all
Ambigüedad	x1	1.000				0.537	0.734
	x2	1.098	0.095	11.542	0.000	0.589	0.756
	x3	0.529	0.076	6.940	0.000	0.284	0.464
	x4	1.232	0.093	13.279	0.000	0.661	0.870
	x5	1.349	0.095	14.200	0.000	0.724	0.868
Conflicto	x6	1.379	0.116	11.922	0.000	0.740	0.822
	x7	1.000				0.495	0.510
	x8	1.563	0.188	8.325	0.000	0.774	0.730
	x9	1.609	0.206	7.811	0.000	0.796	0.676
	x10	1.475	0.196	7.520	0.000	0.730	0.647
Sobrecarga	x11	1.810	0.228	7.932	0.000	0.896	0.802
	x12	1.724	0.234	7.380	0.000	0.853	0.714
	x13	1.838	0.232	7.927	0.000	0.910	0.811
	x14	1.275	0.185	6.907	0.000	0.631	0.597
	x15	1.000				0.916	0.845
	x16	1.084	0.056	19.247	0.000	0.993	0.925
	x17	1.035	0.059	17.621	0.000	0.948	0.849
despersonalización	y1	1.000				0.875	0.826
	y2	1.036	0.058	17.881	0.000	0.906	0.973
	y3	0.675	0.046	14.684	0.000	0.591	0.764
Agotamiento	y4	1.000				0.694	0.732
	y5	1.312	0.126	10.407	0.000	0.911	0.801
	y6	1.043	0.101	10.311	0.000	0.724	0.760
Falta Realización	y7	1.000				0.737	0.870
	y8	0.813	0.081	9.981	0.000	0.599	0.723
	y9	0.561	0.066	8.523	0.000	0.413	0.604

Tabla 20. Parámetros estimados de los errores por el método de mínimos cuadrados generalizados en R.

	Estimate	Std.err	Std.lv	Std.all
x1	0.246	0.024	0.246	0.461
x2	0.260	0.027	0.260	0.428
x3	0.294	0.027	0.294	0.785
x4	0.141	0.017	0.141	0.244
x5	0.172	0.021	0.172	0.247
x6	0.262	0.029	0.262	0.324
x7	0.696	0.063	0.696	0.740
x8	0.525	0.056	0.525	0.467
x9	0.756	0.069	0.756	0.544
x10	0.738	0.072	0.738	0.581
x11	0.446	0.049	0.446	0.357
x12	0.702	0.068	0.702	0.491
x13	0.430	0.049	0.430	0.342
x14	0.717	0.067	0.717	0.643
x15	0.336	0.037	0.336	0.286
x16	0.166	0.030	0.166	0.144
x17	0.349	0.038	0.349	0.280
y1	0.355	0.041	0.355	0.317
y2	0.046	0.030	0.046	0.053
y3	0.248	0.025	0.248	0.416
y4	0.416	0.050	0.416	0.464
y5	0.463	0.067	0.463	0.358
y6	0.384	0.046	0.384	0.423
y7	0.175	0.045	0.175	0.244
y8	0.328	0.039	0.328	0.478
y9	0.298	0.029	0.298	0.635

Las ecuaciones de este modelo quedan de la siguiente forma:

$$\begin{array}{lll}
 X_1 = 1\xi_1 + 0,246 & X_7 = 1\xi_2 + 0,696 & X_{13} = 1,838\xi_2 + 0,430 \\
 X_2 = 1,098\xi_1 + 0,260 & X_8 = 1,563\xi_2 + 0,525 & X_{14} = 1,275\xi_2 + 0,717 \\
 X_3 = 0,529\xi_1 + 0,294 & X_9 = 1,609\xi_2 + 0,756 & X_{15} = 1\xi_3 + 0,336 \\
 X_4 = 1,232\xi_1 + 0,141 & X_{10} = 1,475\xi_2 + 0,738 & X_{16} = 1,084\xi_3 + 0,166 \\
 X_5 = 1,379\xi_1 + 0,172 & X_{11} = 1,810\xi_2 + 0,446 & X_{17} = 1,035\xi_3 + 0,349 \\
 X_6 = 1,379\xi_1 + 0,262 & X_{12} = 1,724\xi_2 + 0,696 & Y_1 = 1\xi_4 + 0,349
 \end{array}$$

$$\begin{aligned}
Y_2 &= 1,036\xi_4 + 0,046 & Y_5 &= 1,312\xi_5 + 0,463 & Y_8 &= 1,813\xi_6 + 0,328 \\
Y_3 &= 0,675\xi_4 + 0,248 & Y_6 &= 1,043\xi_5 + 0,384 & Y_9 &= 0,561\xi_6 + 0,298 \\
Y_4 &= 1\xi_5 + 0,416 & Y_7 &= 1\xi_6 + 0,175
\end{aligned}$$

En estas ecuaciones, tenemos que las regresiones de la primera variables observable que afecta a cada variable latente es 1, como nos podemos fijar en las variables x1, o x7. El resto de regresiones suelen ser superiores a 1 salvo en las variables x3 con un valor de 0,529, y3 con un valor de 0,675 y la variable y9 con un valor de 0,561.

Vamos a estudiar el modelo mediante el método de máxima verosimilitud, de forma similar, introduciendo la siguiente sintaxis:

Modelo <-

'Ambiguedad= ~ x1+x2+x3+x4+x5+x6

conflicto = ~ x7+x8+x9+x10+x11+x12+x13+x14

Sobrecarga= ~ x15+x16+x17

despersonalizacion= ~ y1+y2+y3

Agotamiento= ~ y4+y5+y6

FaltaRealizacion= ~ y7+y8+y9 '

Ajuste <- sem(Modelo, data=Datos, estimator="ML")

Y para mostrar los resultados realizaremos la sintaxis:

summary(Ajuste, fit.measures=T, standardized=T)

lavaan (0.5-16) converged normally after 54 iterations

<i>Number of observations</i>	<i>349</i>
<i>Estimator</i>	<i>ML</i>
<i>Minimum Function Test Statistic</i>	<i>609.668</i>
<i>Degrees of freedom</i>	<i>284</i>
<i>P-value (Chi-square)</i>	<i>0.000</i>

Model test baseline model:

<i>Minimum Function Test Statistic</i>	<i>5364.288</i>
<i>Degrees of freedom</i>	<i>325</i>
<i>P-value</i>	<i>0.000</i>

User model versus baseline model:

<i>Comparative Fit Index (CFI)</i>	0.935
<i>Tucker-Lewis Index (TLI)</i>	0.926

Loglikelihood and Information Criteria:

<i>Loglikelihood user model (H0)</i>	-11154.596
<i>Loglikelihood unrestricted model (H1)</i>	-10849.762
<i>Number of free parameters</i>	67
<i>Akaike (AIC)</i>	22443.192
<i>Bayesian (BIC)</i>	22701.482
<i>Sample-size adjusted Bayesian (BIC)</i>	22488.936

Root Mean Square Error of Approximation:

<i>RMSEA</i>	0.057
<i>90 Percent Confidence Interval</i>	0.051 0.064
<i>P-value RMSEA ≤ 0.05</i>	0.028

Standardized Root Mean Square Residual:

<i>SRMR</i>	0.061
-------------	-------

Parameter estimates:

<i>Information</i>	<i>Expected</i>
<i>Standard Errors</i>	<i>Standard</i>

	<i>Estimate</i>	<i>Std.err</i>	<i>Z-value</i>	<i>P(> z)</i>	<i>Std.lv</i>	<i>Std.all</i>
<i>Latent variables:</i>						
<i>Ambigüedad =~</i>						
<i>x1</i>	1.000			0.628	0.749	
<i>x2</i>	1.130	0.079	14.380	0.000	0.710	0.759
<i>x3</i>	0.677	0.065	10.397	0.000	0.425	0.562
<i>x4</i>	1.252	0.074	16.914	0.000	0.787	0.879
<i>x5</i>	1.300	0.078	16.681	0.000	0.817	0.867
<i>x6</i>	1.322	0.086	15.395	0.000	0.831	0.806
<i>conflicto =~</i>						
<i>x7</i>	1.000			0.499	0.459	
<i>x8</i>	1.623	0.208	7.799	0.000	0.809	0.665
<i>x9</i>	1.657	0.213	7.764	0.000	0.827	0.658
<i>x10</i>	1.574	0.210	7.495	0.000	0.785	0.611
<i>x11</i>	1.937	0.232	8.333	0.000	0.966	0.786
<i>x12</i>	1.865	0.233	8.003	0.000	0.930	0.707
<i>x13</i>	2.003	0.239	8.364	0.000	0.999	0.795
<i>x14</i>	1.494	0.200	7.455	0.000	0.745	0.604
<i>Sobrecarga =~</i>						

<i>x15</i>	1.000			1.049	0.857	
<i>x16</i>	1.083	0.046	23.559	0.000	1.136	0.934
<i>x17</i>	1.060	0.050	21.410	0.000	1.112	0.873
<i>despersonalizacion</i> =~						
<i>y1</i>	1.000			0.960	0.821	
<i>y2</i>	1.025	0.050	20.544	0.000	0.983	0.973
<i>y3</i>	0.681	0.040	16.842	0.000	0.654	0.771
<i>Agotamiento</i> =~						
<i>y4</i>	1.000			0.885	0.749	
<i>y5</i>	1.128	0.084	13.363	0.000	0.998	0.780
<i>y6</i>	1.009	0.074	13.599	0.000	0.893	0.799
<i>FaltaRealizacion</i> =~						
<i>y7</i>	1.000			0.789	0.844	
<i>y8</i>	0.971	0.072	13.529	0.000	0.766	0.785
<i>y9</i>	0.653	0.057	11.425	0.000	0.516	0.638

Covariances:

Ambigüedad ~~

<i>conflicto</i>	-0.088	0.022	-4.010	0.000	-0.280	-0.280
<i>Sobrecarga</i>	-0.092	0.039	-2.378	0.017	-0.140	-0.140
<i>despersonalizcn</i>	-0.232	0.039	-5.871	0.000	-0.384	-0.384
<i>Agotamiento</i>	-0.151	0.037	-4.125	0.000	-0.272	-0.272
<i>FaltaRealizcn</i>	0.272	0.037	7.323	0.000	0.548	0.548

conflicto ~~

<i>Sobrecarga</i>	0.241	0.043	5.573	0.000	0.460	0.460
<i>despersonalizcn</i>	0.127	0.032	3.929	0.000	0.266	0.266
<i>Agotamiento</i>	0.161	0.035	4.629	0.000	0.365	0.365
<i>FaltaRealizcn</i>	-0.043	0.025	-1.690	0.091	-0.109	-0.109

Sobrecarga ~~

<i>despersonalizcn</i>	0.212	0.059	3.569	0.000	0.211	0.211
<i>Agotamiento</i>	0.624	0.075	8.346	0.000	0.672	0.672
<i>FaltaRealizcn</i>	-0.040	0.051	-0.782	0.434	-0.048	-0.048

despersonalizacion ~~

<i>Agotamiento</i>	0.289	0.057	5.106	0.000	0.341	0.341
<i>FaltaRealizcn</i>	-0.273	0.050	-5.446	0.000	-0.360	-0.360

Agotamiento ~~

<i>FaltaRealizcn</i>	-0.158	0.047	-3.365	0.001	-0.227	-0.227
----------------------	--------	-------	--------	-------	--------	--------

Variances:

<i>x1</i>	0.310	0.026		0.310	0.440	
<i>x2</i>	0.372	0.032		0.372	0.425	
<i>x3</i>	0.391	0.031		0.391	0.684	
<i>x4</i>	0.183	0.020		0.183	0.228	
<i>x5</i>	0.220	0.023		0.220	0.248	
<i>x6</i>	0.371	0.033		0.371	0.350	
<i>x7</i>	0.931	0.073		0.931	0.789	
<i>x8</i>	0.826	0.070		0.826	0.558	
<i>x9</i>	0.893	0.075		0.893	0.566	
<i>x10</i>	1.037	0.085		1.037	0.627	

<i>x11</i>	0.577	0.056	0.577	0.382
<i>x12</i>	0.868	0.076	0.868	0.501
<i>x13</i>	0.583	0.057	0.583	0.369
<i>x14</i>	0.967	0.079	0.967	0.635
<i>x15</i>	0.397	0.039	0.397	0.265
<i>x16</i>	0.189	0.031	0.189	0.127
<i>x17</i>	0.387	0.040	0.387	0.238
<i>y1</i>	0.447	0.044	0.447	0.327
<i>y2</i>	0.053	0.029	0.053	0.052
<i>y3</i>	0.291	0.026	0.291	0.405
<i>y4</i>	0.612	0.061	0.612	0.439
<i>y5</i>	0.643	0.069	0.643	0.392
<i>y6</i>	0.452	0.052	0.452	0.362
<i>y7</i>	0.251	0.040	0.251	0.287
<i>y8</i>	0.366	0.044	0.366	0.384
<i>y9</i>	0.388	0.034	0.388	0.593
<i>Ambigüedad</i>	0.395	0.049	1.000	1.000
<i>conflicto</i>	0.249	0.058	1.000	1.000
<i>Sobrecarga</i>	1.101	0.112	1.000	1.000
<i>despersonalizcn</i>	0.921	0.102	1.000	1.000
<i>Agotamiento</i>	0.783	0.103	1.000	1.000
<i>FaltaRealizcn</i>	0.623	0.072	1.000	1.000

Obteniendo los resultados siguientes que compararemos con los obtenidos en AMOS:

Tabla 21 comparación de los resultados de bondad de ajuste entre R y AMOS, mediante el método de máxima verosimilitud.

Medida de ajuste	Modelo R	Modelo AMOS
NNFI	0,926	0,927
CFI	0,935	0,935
RMSEA	0.057	0,057
LO 90	0.051	0,051
HI 90	0.064	0,063
SRMR	0.061	0,0662

En la tabla 21 se puede ver como los estadísticos de bondad de ajuste son prácticamente iguales, no habiendo diferencias significativas entre ambos programas. Siendo este modelo, como concluimos en el modelo estudiado en AMOS, un modelo con un buen ajuste de los datos. En la tabla 22 podemos comparar todas las regresiones de las variables. Al igual que el modelo de mínimos cuadrados generalizados, la primera variable asociada a cada variable latente, sigue teniendo como valor de regresión 1. los valores de los estimadores están todos por encima de 1 salvo x3, y4 e y9, con valores de 0,677, 0,681 y 0,971. La estimación más alta la podemos encontrar en la variable x14 con un valor de 2,003 siendo este el único valor que sobre pasa de 2.

Tabla 22. Parámetros estimados por el método de máxima verosimilitud en R.

		Estimate	Std.err	Z-value	P(> z)	Std.lv	Std.all
Ambigüedad	x1	1.000	0.628	0.749			
	x2	1.130	0.079	14.380	0.000	0.710	0.759
	x3	0.677	0.065	10.397	0.000	0.425	0.562
	x4	1.252	0.074	16.914	0.000	0.787	0.879
	x5	1.300	0.078	16.681	0.000	0.817	0.867
Conflicto	x6	1.322	0.086	15.395	0.000	0.831	0.806
	x7	1.000	0.499	0.459			
	x8	1.623	0.208	7.799	0.000	0.809	0.665
	x9	1.657	0.213	7.764	0.000	0.827	0.658
	x10	1.574	0.210	7.495	0.000	0.785	0.611
	x12	1.937	0.232	8.333	0.000	0.966	0.786
	x13	1.865	0.233	8.003	0.000	0.930	0.707
	x14	2.003	0.239	8.364	0.000	0.999	0.795
Sobrecarga	x15	1.494	0.200	7.455	0.000	0.745	0.604
	x16	1.000	1.049	0.857			
	x17	1.083	0.046	23.559	0.000	1.136	0.934
despersonalización	y1	1.060	0.050	21.410	0.000	1.112	0.873
	y2	1.000	0.960	0.821			
	y3	1.025	0.050	20.544	0.000	0.983	0.973
Agotamiento	y4	0.681	0.040	16.842	0.000	0.654	0.771

	y5	1.000	0.885	0.749			
	y6	1.128	0.084	13.363	0.000	0.998	0.780
Falta Realización	y7	1.009	0.074	13.599	0.000	0.893	0.799
	y8	1.000	0.789	0.844			
	y9	0.971	0.072	13.529	0.000	0.766	0.785

Tabla 23. Errores estimados mediante el método de máxima verosimilitud.

	Estimate	Std.err	Std.lv	Std.all
x1	0.310	0.026	0.310	0.440
x2	0.372	0.032	0.372	0.425
x3	0.391	0.031	0.391	0.684
x4	0.183	0.020	0.183	0.228
x5	0.220	0.023	0.220	0.248
x6	0.371	0.033	0.371	0.350
x7	0.931	0.073	0.931	0.789
x8	0.826	0.070	0.826	0.558
x9	0.893	0.075	0.893	0.566
x10	1.037	0.085	1.037	0.627
x11	0.577	0.056	0.577	0.382
x12	0.868	0.076	0.868	0.501
x13	0.583	0.057	0.583	0.369
x14	0.967	0.079	0.967	0.635
x15	0.397	0.039	0.397	0.265
x16	0.189	0.031	0.189	0.127
x17	0.387	0.040	0.387	0.238
y1	0.447	0.044	0.447	0.327
y2	0.053	0.029	0.053	0.052
y3	0.291	0.026	0.291	0.405
y4	0.612	0.061	0.612	0.439
y5	0.643	0.069	0.643	0.392
y6	0.452	0.052	0.452	0.362
y7	0.251	0.040	0.251	0.287
y8	0.366	0.044	0.366	0.384
y9	0.388	0.034	0.388	0.593

Las ecuaciones de este modelo quedan de la siguiente forma:

$$\begin{array}{lll}
 X_1 = 1\xi_1 + 0,310 & X_3 = 0,677\xi_1 + 0,391 & X_5 = 1,300\xi_1 + 0,220 \\
 X_2 = 1,130\xi_1 + 0,372 & X_4 = 1,252\xi_1 + 0,183 & X_6 = 1,3322\xi_1 + 0,3712
 \end{array}$$

$X_7 = 1\xi_2 + 0,931$	$X_{14} = 1,494\xi_2 + 0,967$	$Y_4 = 1\xi_5 + 0,612$
$X_8 = 1,623\xi_2 + 0,826$	$X_{15} = 1\xi_3 + 0,397$	$Y_5 = 1,128\xi_5 + 0,643$
$X_9 = 1,657\xi_2 + 0,893$	$X_{16} = 1,083\xi_3 + 0,189$	$Y_6 = 1,009\xi_5 + 0,452$
$X_{10} = 1,574\xi_2 + 1,037$	$X_{17} = 1,060\xi_3 + 0,387$	$Y_7 = 1\xi_6 + 0,251$
$X_{11} = 1,937\xi_2 + 0,577$	$Y_1 = 1\xi_4 + 0,447$	$Y_8 = 0,971\xi_6 + 0,366$
$X_{12} = 1,865\xi_2 + 0,868$	$Y_2 = 1,083\xi_4 + 0,053$	$Y_9 = 0,653\xi_6 + 0,388$
$X_{13} = 2,003\xi_2 + 0,583$	$Y_3 = 0,681\xi_4 + 0,291$	

Conclusión

En los últimos años, R se está convirtiendo en una de las alternativas validas para los paquetes estadísticos usados comúnmente, gracias a ser un programa estadístico de uso gratuito. Con respecto a las ecuaciones estructurales, AMOS tiene la ventaja de ser un programa muy intuitivo, donde tiene una representación gráfica bastante buena y una gran variedad de estadísticos de bondad de ajustes. Esto hace que la interpretación de los resultados sea bastante sencilla y rápida, pero la introducción del modelo en el programa es bastante tediosa y lenta. Además, este programa solo te deja realizar el ajuste por los métodos clásicos de estimación, sin tener en cuenta los nuevos métodos. En cambio, el paquete lavaan de R, tiene la dificultad de no poder representar gráficamente los modelos, esto dificulta bastante la interpretación de los resultados, siendo estos unos de los principales problemas que tiene este programa, junto a la limitada lista de estadístico de bondad de ajuste que ofrece el programa. Por el contrario, tiene como principales ventajas, la sencillez y rapidez de programación de los modelos así como la variedad de métodos de estimación.

Además, este trabajo sirve para poder ver cómo, el modelo puede tener un ajuste diferente según el método de resolución aplicado. De forma que, para nuestro modelo, al hallar el modelo mediante el método de mínimos cuadrados generalizados se obtiene que el modelo no se ajusta bien a los datos, y sin embargo el mismo modelo pero resuelto por el método de máxima verosimilitud se obtiene que el modelo se ajusta bien a los datos.

Bibliografía:

Batista Fouguet, J.M. y Coenders Gallart, G. (2000) Modelos de ecuaciones estructurales.

Cronbach, L. J. (1951). Coefficient alpha and the internal structure of the tests. *Psychometrika*, 16, 297-334.

N. Henze, B. Zirkler, A class of invariant and consistent tests for multivariate normality, *Comm. Statist. Theory Methods* 19 (1990) 3595–3617.

Maas, C. J. M. y J. J. Hox (2004), The influence of violations of assumptions on multilevel parameter estimates and their standard errors. *Computational Statistics & Data Analysis* 46, 427–440.

Chou, C. P., P. M. Bentler y A. Satorra (1991), Scaled test statistics and robust standard errors for non-normal data in covariance structure analysis: a Monte Carlo study. *British Journal of Mathematical and Statistical Psychology* 44, 347–357.

Curran, P. J., S. G. West y J. F. Finch (1996), The robustness of test statistics to nonnormal- ity and specification error in confirmatory factor analysis. *Psychological Methods* 1, 16–29.

Jöreskog, K. G. and Sörbom (1996). *LISREL 8 : User's Reference Guide*. Scientific Software International, Chicago.

Hox, J. J., Maas, C. J. M. and Brinkhuis, M. J. S. (2010), The effect of estimation method and sample size in multilevel structural equation modeling. *Statistica Neerlandica*, 64: 157–170. doi: 10.1111/j.1467-9574.2009.00445.x

Hu, L.T. and Bentler, P.M. (1999), "Cutoff Criteria for Fit Indexes in Covariance Structure Analysis: Conventional Criteria Versus New Alternatives," *Structural Equation Modeling*, 6 (1), 1-55.

Hopper, D., Coughlan, J, Mullen, M.R. (2008), *Electronic Journal of Business Research Methods* Volume 6 Issue 1 (53-60)

Rosseel, Y. (2012a). lavaan: an R package for structural equation modeling. *Journal of Statistical Software* (in press).

Rosseel, Y. (2012b). Package 'lavaan'. Disponible en: <http://cran.r-project.org/web/packages/lavaan/lavaan.pdf>

Rosseel, Y. (2011). Lavaan: an R package for structural equation modelling and more. Version 0.4-9 (BETA). Disponible en <http://users.ugent.be/~yrosseel/lavaan/lavaanIntroduction.pdf>

Herrero, J. (2010) Confirmatory Factor Analysis in the study of the Structure and Stability of Assessment Instruments: An example with the Self-Esteem Questionnaire 289-300. DOI: 10.5093/in2010v19n3a9

Ruiz, M. A. Pardo, A. y San Martín, R. Modelos de ecuaciones estructurales. Papeles del Psicólogo, 2010. Vol31, 34-45.

Byrne, B. M. (1998). Structural Equation Modeling with LISREL, PRELIS, and SIMPLIS: Basic Concepts, Applications, and Programming. Mahwah: Lawrence Erlbaum Associates, Inc.

Arias, B. (2008). Desarrollo de un ejemplo de análisis factorial confirmatorio con LISREL, AMOS y SAS. Seminario de actualización en Investigación sobre Discapacidad SAID. Universidad de Valladolid

Arbuckle, J. L (2008). Amos 17.0 user's guide.